



Veri Madenciliği FET445

2025-2026 Güz Dönemi

Trafik Kazalarından Yaralanma Şiddetinin Tahmini

Grup İsmi: *Lumina*

Grup Üyeleri:

1.Üye:Kübra Beyza Aybar - 22040301017

2.Üye: Şule Kartal - 22040301049

3. Üye: Dilara Kurtul - 22040301061

4.Üye: Yağmur Deveci - 22040301057

5.Üye: Emine Esra Çetin - 22040301014

Grup Github Linki: https://github.com/eessrac/Lumina_VeriMadenciligi

1.PROBLEM TANIMI

Bu Proje Hangi Sorunun Cevabını Arıyor?

Bu proje, büyük şehirlerde artan trafik yoğunluğu ve bunun sonucu oluşan kazaların ciddiyetini daha iyi anlamayı amaçlamaktadır. Chicago Traffic Crashes veri seti kullanılarak hava koşulları, yol durumu, ışıklandırma, trafik kontrol cihazları ve konum gibi faktörlerin kazalar üzerindeki etkisi analiz edilmektedir.

Ana Bilimsel Soru

Trafik kazalarını en çok etkileyen faktörler nelerdir ve bu faktörlere dayanarak yaralanma türü doğru şekilde tahmin edilebilir mi?

Sonuç olarak, bu proje, trafik kazalarını etkileyen temel faktörleri bilimsel olarak incelemeyi ve bu faktörlere dayanarak öngörücü modeller geliştirmeyi amaçlamaktadır. Böylece hem akademik hem de pratik düzeyde daha güvenli şehirler için karar destek sistemi niteliği taşıyan sonuçlar sunmayı hedeflemektedir.

Görev Türü

Bu proje, trafik kazası verilerine dayanarak yaralanma türünü tahmin etmeyi amaçladığı için Sınıflandırma (Classification) problemine karşılık gelmektedir.

Hedef Değişken

Hedef Değişken: MOST_SEVERE_INJURY

MOST_SEVERE_INJURY değişkeni, bir trafik kazasında meydana gelen en ciddi yaralanma düzeyini ifade eden kategorik bir değişkendir. Bu değişken, kazanın şiddetini belirlemek ve yüksek riskli kazaları analiz etmek için temel bir göstergedir. Trafik güvenliği, risk analizi ve yaralanma tahmin modellerinde kritik bir hedef değişken olarak kullanılır.

Değişkenin Etki Alanı

MOST_SEVERE_INJURY değişkeni, veri setinde aşağıdaki kategorilerden birini alabilir:

Trafik kazalarında yaralanma şiddeti aşağıdaki kategorilerle tanımlanmaktadır:

- **No Indication Of Injury:** Yaralanma Belirtisinin Bulunmadığı Durumlar.
- **Nonincapacitating Injury:** Hafif Yaralanmalar
- **Incapacitating Injury:** Ciddi Yaralanmalar; Kişinin Yürüyemediği Veya İşlev Kaybı Yaşadığı Durumlar.
- **Reported Not Evident:** Dışarıdan Belirgin Bir Yaralanma Görülmeyen Durumlar.
- **Fatal:** Ölümle Sonuçlanan Yaralanmalar.
- **Unknown:** Yaralanma Durumunun Belirlenemediği Veya Kaydedilmediği Durumlar.

Başarı Kriterleri (Model Oluşturulmadan Önce Belirlenen Hedefler)

Bu çalışmada henüz modelleme aşaması gerçekleştirilmemiştir. Bu nedenle aşağıda verilen metrikler, modelden beklenen hedef performans kriterleri olup, ilerleyen aşamalarda kurulan modeller bu hedeflerle karşılaştırılacaktır.

1. ROC AUC - Hedef: ROC AUC ≥ 0.80

- Bu deęer, modelin sınıfları ayırt etme becerisinin kabul edilebilir minimum seviyesini temsil eder. Gerçek performans modelleme aşamasında ölçülecektir.

2. Accuracy - Hedef: Accuracy ≥ 0.75

- Bu eşik, çok sınıflı yapıda genel doğruluk için minimum beklentiyi tanımlar.

3. Macro F1-Score - Hedef: Macro F1 ≥ 0.70

- Sınıf dengesizliği nedeniyle tüm sınıflar için dengeli bir performans hedeflenmektedir.

4. Recall - Hedef: Recall ≥ 0.60

- Kritik sınıf (ölümlü kazalar) için minimum duyarlılık hedefidir.

2.PROJE YÖNETİMİ

Zaman Çizelgesi

Bu bölümde projenin tamamlanan adımları ve gelecek haftalarda uygulanması planlanan süreçler ayrıntılı biçimde verilmiştir.

Tamamlanan Aşamalar:

1. Hafta (20–27 Ekim) – Proje Tanımlama ve Veri Seti Seçimi

- Proje konusu belirlendi: Trafik kazalarında yaralanma şiddeti tahmini.
 - Veri seti seçildi: Chicago Traffic Crashes – Crashes Dataset.
 - Hedef deęişken: MOST_SEVERE_INJURY olarak tanımlandı.
 - Proje ekibi oluşturuldu (Esra, Kübra, Dilara, Şule, Yağmur).
 - Veri setinin kapsamı, boyutu, deęişken türleri ve veri kaynağı incelendi.
- Sorumlu: Tüm ekip

2. Hafta (3–10 Kasım) – Veri Ön İşleme ve EDA Hazırlığı

- Eksik deęer analizi yapıldı (sütun bazında eksik oran hesaplamaları).
 - Veri tipi dönüşümleri ve gereksiz sütunların tespiti gerçekleştirildi.
 - Aykırı deęer kontrolü yapıldı.
 - Yüksek kardinaliteli deęişkenler incelendi.
 - Deęişkenlerin ilk dağılım grafikleri çıkarıldı.
 - Hedef deęişken MOST_SEVERE_INJURY için sınıf dağılımı analiz edildi.
- Sorumlu: Tüm ekip

3. Hafta (10–17 Kasım) – Veri Hazırlama ve Base Modeller

- Eksik deęer oranları analiz edilerek en problemli sütunlar belirlendi ve gereksiz/bozucu deęişkenler (konum, ID, zaman damgası, leakage oluşturan yaralanma deęişkenleri) çıkarıldı.
- Aşırı eksik veya anlamsız kategorilere sahip sütunlar temizlendi; deęişkenler sayısal ve kategorik olarak ayrıldı.
- Hedef deęişkenin sınıf dağılımı incelendi ve dengesizlik tespit edildi. One-Hot Encoding yapılacak kategorik alanlar seçildi; hava durumu, ışıklandırma, saat, mevsim gibi deęişkenlerin hedefle ilişkisi deęerlendirildi.

- Sayısal değişkenler için histogram, boxplot ve aykırı değer analizleri yapıldı; korelasyon matrisi ile multicollinearity kontrol edildi.
- Uygun base modeller seçilerek ilk eğitimler gerçekleştirildi; accuracy, F1-score ve confusion matrix sonuçları elde edildi. Base model çıktıları analiz edilerek sonraki aşama için performans hedefleri belirlendi.

Sorumlu: Tüm ekip

4. Hafta (17 Kasım-1 Aralık) – Gelişmiş Modelleme

- Temel modeller tamamlandıktan sonra proje ileri faza taşınmıştır.
- Veri içerisindeki doğrusal olmayan ilişkilerin daha iyi öğrenilebilmesi amacıyla gelişmiş modelleme yaklaşımları uygulanmıştır.
- Tüm modeller aynı veri hazırlama ve ön işleme adımları kullanılarak eğitilmiştir.
- Veri sızıntısını önlemek için modelleme süreci Pipeline yapıları içerisinde yürütülmüştür.
- Yüksek boyutlu özellik uzayının model performansı üzerindeki etkisi analiz edilmiştir.

Sorumlu: Tüm Ekip (Herkes kendi modeli üzerinde bu işlemleri yapacaktır.)

5. Hafta (1 - 8 Aralık)– Hiperparametre Optimizasyonu ve Model Derinleştirme

- Modeller, sabit hiperparametre ayarlarıyla eğitilerek performans karşılaştırmaları yapılmıştır.
- Model karmaşıklığı ve genelleme performansı, eğitim ve test sonuçları üzerinden değerlendirilmiştir.
- Sınıf dengesizliğinin model çıktıları üzerindeki etkisi analiz edilmiştir.
- Performans değerlendirmeleri accuracy, precision, recall ve F1-score metrikleri kullanılarak gerçekleştirilmiştir.
- Farklı modelleme yaklaşımlarının güçlü ve zayıf yönleri karşılaştırmalı olarak incelenmiştir.

Sorumlu: Tüm Ekip (Herkes kendi modeli üzerinde bu işlemleri yapacaktır.)

6. Hafta(8- 15 Aralık) – Performans Analizi, Model Seçimi ve Nihai Değerlendirme

- Test veri kümesi üzerinde elde edilen sonuçlar doğrultusunda modeller ayrıntılı biçimde değerlendirilmiştir.
- Her model için çok sınıflı karışıklık matrisleri (confusion matrix) oluşturulmuş ve hata örüntüleri analiz edilmiştir.
- Modellerin sınıf bazlı performansları karşılaştırılmıştır.
- Elde edilen metrikler doğrultusunda en dengeli ve yüksek performanslı model belirlenmiştir.
- Modelin güçlü ve zayıf yönleri sonuçlar üzerinden yorumlanmıştır.

Sorumlu: Tüm Ekip (Herkes kendi modeli üzerinde bu işlemleri yapacaktır.)

7. Hafta(15-25 Aralık) – Raporlama ve Sunum Hazırlığı

- Proje raporu teknik ve akademik yazım kurallarına uygun şekilde tamamlanmıştır.
- Modelleme süreci, değerlendirme sonuçları ve bulgular rapor hâline getirilmiştir.
- Sonuç ve tartışma bölümleri yazılarak çalışma genel olarak değerlendirilmiştir.
- Model performanslarını gösteren tablolar ve karışıklık matrisleri sunuma uygun biçimde hazırlanmıştır.
- Ekip içi kontroller yapılarak gerekli düzenlemeler tamamlanmış ve çalışma teslim aşamasına getirilmiştir.

Sorumlu: Tüm ekip

3.İLGİLİ ÇALIŞMALAR (LİTERATÜR İNCELEMESİ)

Trafik kazası şiddetinin tahmin edilmesi, ulaşım güvenliğini artırmak ve kazaların yol açtığı kayıpları minimize etmek amacıyla literatürde sıkça çalışılan bir konudur. Bu bölümde, farklı veri ölçekleri ve metodolojik yaklaşımlar kullanan üç temel çalışma incelenmiş; kullanılan algoritmalar, veri setleri ve performans sonuçları karşılaştırılmıştır.

3.1. Çalışmaların Detaylı İncelemesi

1. Geniş Ölçekli Veri Seti ile Kapsamlı Algoritma Karşılaştırması (Türker ve Gündüz, 2023)

Türker ve Gündüz tarafından yapılan çalışmada, ABD'nin 49 eyaletini kapsayan ve 2016- 2023 yıllarını içeren yaklaşık 7.7 milyon kayıtlık devasa bir veri seti kullanılmıştır. Çalışmanın temel amacı, yol bozuklukları, hava koşulları ve araç hızı gibi faktörleri kullanarak kaza şiddetini (hafif, orta, ciddi, ölümcül) sınıflandırmaktır.

- **Yöntem:** Decision Tree (DT), Random Forest (RF), Logistic Regression (LR), SVM, K-NN ve Naive Bayes algoritmaları karşılaştırılmıştır.

- **Sonuç:** Decision Tree algoritması, %99.6 doğruluk oranı (accuracy) ile en yüksek performansı göstermiş, onu %99.3 ile Random Forest izlemiştir. Buna karşın Naive Bayes (%42) ve Logistic Regression (%62) modelleri büyük veri setinde daha düşük performans sergilemiştir.

2. Nedensellik Analizi ve Hibrit Sınıflandırma Yaklaşımı (Chakraborty vd., 2021)

Chakraborty ve ekibi, Teksas eyaletindeki otoyollarda (interstate) 2014-2019 yılları arasında gerçekleşen 156.166 kaza kaydını inceleyerek istatistiksel yöntemler ile makine öğrenmesini birleştirmiştir. Bu çalışmanın ayırt edici özelliği, tahmin modellemesinden önce değişkenlerin önemini belirlemek için Granger Nedensellik Testi kullanmasıdır.

- **Yöntem:** Veri dengesizliğini gidermek için SMOTE tekniği uygulanmış; Decision Tree, Random Forest, XGBoost ve Derin Sinir Ağları (DNN) kullanılmıştır .

- **Sonuç:** Çalışma, "tek bir en iyi modelin" olmadığını ortaya koymuştur. Maddi hasarlı (PDO) kazalarda Decision Tree en iyisiyken, hafif yaralanmalı kazalarda Random Forest öne çıkmıştır. Ancak, veri setindeki en nadir ve kritik sınıf olan ölümcül/ciddi yaralanmalı (KA) kazaları tahmin etmede, doğrusal olmayan karmaşık ilişkileri çözebilen Derin Sinir Ağları (DNN) diğer tüm modellerden üstün performans göstermiştir .

3. Metin Madenciliği ve Özellik Mühendisliği Odaklı Yaklaşım (UCLA Grup H, 2022)

UCLA öğrencileri tarafından yürütülen bu çalışmada, Kaggle kaynaklı 50.000 gözlem (35.000 eğitim, 15.000 test) içeren daha küçük ölçekli ancak nitelikli bir veri seti kullanılmıştır¹¹. Çalışma, ham verideki kategorik değişkenlerin (özellikle "Description" sütunu) metin madenciliği (text mining) ile işlenerek modele dahil edilmesine odaklanmıştır.

- **Yöntem:** Kaza açıklamalarındaki "blocked", "closed" gibi anahtar kelimelerden yeni öznitelikler türetilmiş; KNN, XGBoost ve Random Forest modelleri test edilmiştir .

- **Sonuç:** Random Forest algoritması, mtry=37 parametresi ile optimize edildiğinde %93.55 doğruluk oranıyla en başarılı model olmuştur. KNN ise %90'ın altında kalarak en zayıf performansı sergilemiştir.

3.3. Değerlendirme

Literatür incelendiğinde, trafik kazası şiddetinin tahmininde ağaç tabanlı yöntemlerin (Decision Tree ve Random Forest) genel olarak yüksek performans ve kararlılık sergilediği görülmektedir. Ancak veri seti dengesiz olduğunda (ölümcül kazaların azlığı gibi) veya veri boyutu küçüldüğünde, SMOTE gibi dengeleme tekniklerinin ve Derin Öğrenme (DNN) gibi karmaşık yapıları modelleyebilen algoritmaların kritik öneme sahip olduğu anlaşılmaktadır. Ayrıca, ham verilerin metin madenciliği gibi yöntemlerle zenginleştirilmesinin model başarısını doğrudan etkilediği görülmüştür.

4) VERİ TANIMI VE YÖNETİMİ

Veri Seti: Bu projede kullanılan veri seti “Traffic Crashes – Chicago” adlı, Chicago City Open Data Portal tarafından yayımlanan resmi açık veri setidir. Veri, Chicago Polis Departmanı (CPD) tarafından toplanmakta ve kamuya sunulmaktadır. Veri setine internet üzerinden City of Chicago Open Data Portal aracılığıyla erişilmektedir. Bağlantı adresi: <https://data.cityofchicago.org/Public-Safety/Traffic-Crashes-Crashes/85ca-t3if>

Veri seti açık veri kapsamında yayımlandığı için herhangi bir ücret, erişim kısıtlaması veya özel lisans gerektirmez. Chicago Open Data kullanım haklarına göre veri akademik ve araştırma amaçlı serbestçe kullanılabilir. Veri, kişisel kimlik bilgileri içermediği için gizlilik açısından bir risk oluşturmaz ve yalnızca olay bazlı anonimleştirilmiş bilgiler sunar.

Veri Şeması: Bu veri seti, trafik kazalarını çok boyutlu olarak incelemeye uygun, geniş ve çeşitli değişkenlerden oluşmaktadır. Değişkenler dört ana grupta toplanır:

- **Kategorik değişkenler:** Kaza türü, ışık koşulları, hava durumu, yol yüzeyi, trafik kontrol cihazı, hasar derecesi gibi olayın niteliksel özelliklerini içeren alanlardır. Bazıları yüksek kategorik çeşitliliğe sahiptir.
- **Sayısal değişkenler:** Hız limiti, şerit sayısı, kaza saati, gün, ay, olayda yer alan birim sayısı ve yaralı sayısı gibi miktarsal bilgilerden oluşur. Birim ve aralıklar veri setinde net şekilde tanımlanmıştır.
- **Tarih/zaman değişkenleri:** Kazanın gerçekleşme zamanı ve polise bildirim zamanını içeren zamansal verilerdir.
- **Konum değişkenleri:** Enlem, boylam ve adres tabanlı konum tanımları gibi coğrafi bilgilerden oluşur.

Genel olarak veri şeması, kazaları çevresel ve yapısal yönleriyle kapsamlı biçimde açıklamaktadır. Veri temizliği aşamasında model açısından gereksiz, tekrarlı veya leakage riski taşıyan değişkenler çıkarılmıştır.

Boyut: Veri seti başlangıçta 49 sütun ve yaklaşık 1 milyon kayıttan oluşmasına rağmen bu çalışmada 300.000 satır kullanılmış; temizlik ve özellik seçimi sonrası modelleme için 19 sütunluk nihai yapı elde edilmiştir. Hedef değişken MOST_SEVERE_INJURY belirgin biçimde dengesizdir: “NO INDICATION OF INJURY” en büyük sınıfı oluştururken “FATAL” ve “INCAPACITATING INJURY” oldukça düşük frekansa sahiptir. Bu durum, modelleme stratejilerinin ve performans metriklerinin seçiminde belirleyici olmuştur. Genel olarak veri seti yüksek satır sayısı, çok sayıda kategorik değişken ve ciddi sınıf dengesizliği içeren bir yapıya sahiptir.

Veri Eriřim Planı: Bu projede kullanılan Traffic Crashes veri seti, Chicago City Open Data Portal'dan CSV formatında indirilmiř ve tüm analizler yerel ortamda bu tek dosya üzerinden yürütölmüřtür. Veri güncellendiğinde aynı kaynaktan yeni CSV indirilebilir ve mevcut iřleme adımları tekrar uygulanarak modeller yeniden eğitilebilir. Tüm veri depolama ve erişim iřlemleri yerel makinede yapılmıř olup ek bir bulut veya dıř veri tabanı altyapısına ihtiya duyulmamıřtır.

Etik, Gizlilik, Önyargı: Bu projede kullanılan Traffic Crashes veri seti kamuya aık olup kiřisel kimlik bilgisi (PII) iermez; isim, adres, plaka gibi doğrudan tanımlayıcı veriler bulunmamaktadır. Ancak enlem–boyam ve tarih gibi dolaylı konum bilgilerinin yer alması nedeniyle, bu alanların kimlik ıkarımına yönelik kullanılmamasına dikkat edilmiřtir.

Modellemede kimlik tespitine yol aabilecek veya leakage riski taşıyan sütunlar ıkarılarak etik bütönlük korunmuřtur. Veri kamuya aık olduėundan ek bir rıza gerekmemekle birlikte, analizlerin etik sınırlar iinde yürütölmesi ve elde edilen sonuçların yalnızca akademik amalarla kullanılacağı kabul edilmiřtir.

5.KEřİFSEL VERİ ANALİZİ (EDA)

Bu bölümde Chicago trafik kazaları veri seti üzerinde kapsamlı bir Keřifsel Veri Analizi (EDA) gerekleřtirilmiřtir. Analiz; veri kalitesi kontrolleri, daėılım incelemeleri, hedef deėiřken dengesi, özellik–hedef iliřkileri ve görsel veri keřfi bařlıklarında ele alınmıřtır.

5.1 Veri Kalitesi Kontrolleri

5.1.1. Eksik Deėer Analizi

- Tüm sütunlar iin eksik deėer sayısı ve eksik oranı (%) hesaplanmıřtır.
- Eksik oranı en yüksek deėiřkenler grafiklerle analiz edilmiř, yüksek oranda eksik ieren ve analize katkı saėlamayan sütunlar listelenmiřtir.
- İeriėi anlamsız veya %70–80 üzeri eksik olan deėiřkenler veri setinden ıkarılmıřtır (ör. WORKERS_PRESENT_I, CRASH_DATE_EST_I, PHOTOS_TAKEN_I vb.).

5.1.2. Yineleme (Duplicate) Kontrolleri

- Veri setinde satır bazlı tekrar eden kayıt olup olmadıėı kontrol edilmiřtir.
- Trafik kazalarında kayıt ID'leri (ör. CRASH_RECORD_ID) yüksek tekrar riski taşıdığı iin bu sütunlar doğrudan silinerek modeli yanıltabilecek gereksiz tekillikler temizlenmiřtir.

5.1.3. Aykırı Deėer (Outlier) Analizi

- Numerik deėiřkenler iin Boxplot analizleri, IQR yöntemi ile outlier oranı hesaplanmıřtır.
- Analiz sonucunda hız sınırı (POSTED_SPEED_LIMIT), araç sayısı (NUM_UNITS), saat (CRASH_HOUR) gibi deėiřkenlerin çoėunun beklenen aralıklarda olduėu ve aykırı deėerlerin model iin önemli olduėu görölmüřtür.
- Bu nedenle bu projede aykırı deėerler silinmemiř, sadece bilgilendirme amalı raporlanmıřtır.

İki deėiřken iin aykırı deėer oranı yüksektir:

- POSTED_SPEED_LIMIT → yüksek hız sınırlarına ait aykırı değerler (ör. 55, 60, 70, 90)
- NUM_UNITS → olay yerinde çok araçlı kazalar

Diğer değişkenlerde aykırı değer bulunmamaktadır.

5.1.4. Sızıntı (Data Leakage) Kontrolleri

Modelleme sırasında en kritik risk olan veri sızıntısı ciddi biçimde incelenmiş ve giderilmiştir:

- Yaralanma şiddetini doğrudan gösteren değişkenler (INJURIES_TOTAL, INJURIES_FATAL, INJURIES_REPORTED_NOT_EVIDENT vb.) tespit edilip tamamen kaldırılmıştır.
- Kaza sonucu ortaya çıkan değişkenlerin modelde yer almaması sağlanmıştır.
- Böylece modelin “kazadan sonra ortaya çıkan bilgiyi kullanarak yaralanmayı tahmin etmesi” engellenmiş ve modele gerçekçi bir öğrenme zemini sağlanmıştır.


5.2 Dağılımlar ve Denge Analizi

5.2.1. Hedef Değişken Dağılımı (MOST_SEVERE_INJURY)


Hedef dağılımı incelendiğinde veri yüksek derecede dengesizdir:

- NO INDICATION OF INJURY sınıfı → tüm verinin çok büyük kısmı
- FATAL ve INCAPACITATING INJURY sınıfları → nadir (rare class)

Bu dengesizlik nedeniyle modelleme aşamasında class weights veya SMOTE ihtiyacı ortaya çıkmıştır.



Hız Sınırı Dağılımı (POSTED_SPEED_LIMIT)



Histogram grafiğine göre:

- En yoğun hız sınırı 30 km/h olup aşırı baskın bir tepe noktası vardır.
- 10–20 km/h arasındaki düşük hız sınırları azdır.
- 40–45 km/h orta düzeyde temsil edilmektedir.
- 55–70 km/h değerleri aykırı niteliğindedir. Bu dağılımın çarpık olduğu görülmektedir.

CRASH_HOUR (Kaza Saati)

Kaza saatleri incelendiğinde:

- 14:00–18:00 saatleri arasında belirgin artış vardır.
- Gece saatlerinde (0–5 arası) kaza sayısı belirgin şekilde düşmektedir.

Bu durum yoğun trafik saatlerinin kaza artışına etki ettiğini göstermektedir.


CRASH_DAY_OF_WEEK (Haftanın Günü)

- Hafta sonları hariç genel olarak dengeli bir dağılım vardır.
- Hafta içi bazı günlerde kaza sayısı biraz daha yüksektir.

CRASH_MONTH (Ay Dağılımı)

- Ocak–Aralık ayları arasında belirgin dönemsel sıçramalar yoktur.
- Yıl içinde kazaların genel olarak benzer seviyelerde seyrettiği görülmektedir.

5.2.2. Kategorik Değişken Dağılımları



Hava Durumu vs Yaralanma Şiddeti

Grafiğe göre:

- CLEAR (açık hava) koşullarında kaza sayısı diğer tüm koşullara kıyasla açık ara daha yüksektir.
- Havanın temiz olduğu koşullarda yoğun trafik → daha fazla kaza.
- Fog, rain, snow gibi olumsuz hava koşullarında kaza sayısı daha düşüktür fakat yaralanma şiddeti bazen daha yüksektir.

Işık Koşulu vs Yaralanma Şiddeti (Heatmap)




Heatmap sonuçlarına göre:

- En fazla kaza DAYLIGHT döneminde meydana gelmektedir.
- DARKNESS-LIGHTED ROAD daha yüksek orta seviye yaralanmalara sahiptir.
- Tam karanlıkta yetersiz aydınlatma olduğunda INCAPACITATING türü yaralanmalar orantısız olarak daha fazladır.

5.3. Özellik–Hedef İlişkileri

Sayısal Değişkenlerde Boxplot Analizi



Boxplot'lar incelendiğinde:

- CRASH_HOUR, CRASH_DAY_OF_WEEK ve CRASH_MONTH hedef sınıflar arasında büyük farklılık göstermemektedir.
- POSTED_SPEED_LIMIT ve NUM_UNITS değişkenleri yaralanma şiddeti açısından bir ayırt edici potansiyele sahiptir.

Korelasyon Analizi

Aşağıdaki korelasyon matrisi, veri setindeki tüm sayısal değişkenler arasındaki doğrusal ilişkileri değerlendirmek için oluşturulmuştur. İnceleme sonucunda korelasyon değerlerinin tamamının 0.00–0.06 aralığında olduğu görülmektedir. Bu durum:

- Sayısal değişkenlerin birbirleriyle anlamlı bir doğrusal ilişkiye sahip olmadığını,
- Veri setinde multicollinearity (çoklu doğrusal bağlantı) riski bulunmadığını,
- Her sayısal değişkenin modele bağımsız katkı yapabileceğini, göstermektedir.

Öne çıkan bulgular:

- POSTED_SPEED_LIMIT ile diğer değişkenler arasındaki korelasyon neredeyse sıfırdır → hız sınırı kazanın zamanı, günü veya ayından etkilenmemektedir.
- NUM_UNITS (kazaya karışan birim sayısı) ile diğer özellikler de bağımsızdır.
- CRASH_HOUR, CRASH_DAY_OF_WEEK ve CRASH_MONTH arasında da anlamlı bir ilişki yoktur.

Düşük korelasyon değerleri, sayısal değişkenlerin birbirini açıklamadığını ve redundant özellik bulunmadığını göstermektedir. Bu nedenle tüm sayısal değişkenler modelde tutulabilir. Genel olarak korelasyon analizi, veri setinin bağımsız özelliklerden oluştuğunu ve kolinearite kaynaklı bir performans sorununun beklenmediğini ortaya koymaktadır.

6. VERİ HAZIRLAMA

Veri hazırlama sürecinde veri seti kapsamlı bir temizlikten geçirilmiş, yinelenen kayıtlar ve tutarsızlıklar giderilmiş, anomali içeren gözlemler uygun şekilde işlenmiştir. Ayrıca farklı değişken türlerinde oluşabilecek birim farklılıklarının modele etkisini azaltmak için gerekli sütunlarda birim standardizasyonu uygulanmıştır. Dönüşüm ve ön işleme aşamalarında, model varsayımlarına uyumu artırmak ve dağılım bozukluklarını azaltmak amacıyla gerek görülen değişkenlerde ölçeklendirme, normalleştirme ve log-dönüşüm seçenekleri değerlendirilmiştir. Kategorik değişkenler ise modele uyumlu hale getirmek için one-hot encoding yöntemiyle dönüştürülmüştür.

Kübra Beyza Aybar

Bu çalışmada özellik mühendisliği, veri setindeki ham değişkenleri daha açıklayıcı ve model tarafından daha kolay öğrenilebilir hâle getirmek amacıyla uygulanmıştır. Özellik mühendisliği adımlarında domain bilgisi, kategorik dönüştürme, etkileşim özellikleri ve zaman temelli türetilmeler birlikte kullanılarak veri setinin temsil gücü artırılmıştır. Böylece modelin karmaşık örüntüleri daha iyi yakalaması ve genel performansın iyileştirilmesi hedeflenmiştir.

1. Özellik Mühendisliği

Etki Alanı Özellikleri: Trafik alanına özgü bilgiler kullanılarak daha açıklayıcı değişkenler üretilmiştir.

- CRASH_HOUR_GROUP: Kaza saatleri trafik yoğunluğuna göre (GECE, SABAH_YOGUN, GUNDUZ vb.) gruplandırılmıştır.
- CRASH_SEASON: Ay bilgisi mevsim kategorilerine dönüştürülmüştür.

- ROAD_RISK: Yol tipleri risk seviyelerine göre yeniden sınıflandırılmıştır. Bu tür özellikler, gerçek hayattaki trafik dinamiklerini doğrudan modele aktarır.

Kategori Türetilmesi (Binning): Sürekli değişkenler anlamlı aralıklara bölünerek kategorik özellikler üretilmiştir.

- SPEED_CAT: Hız limitleri düşük–orta–yüksek olacak şekilde üç kategoriye ayrılmıştır.
- DAMAGE_CAT: Araç hasarı seviyeleri 0–1–2 şeklinde sayısal forma dönüştürülmüştür. Bu işlem, değişkenlerin doğrusal olmayan etkilerini daha görünür kılar.

Zaman Temelli Özellikler : Kazaların zaman paternlerini yakalamak amacıyla çeşitli zaman göstergeleri oluşturulmuştur.

- IS_NIGHT: Saatten gece/gündüz bilgisi türetilmiştir.
- IS_WEEKEND: Gün bilgisinden hafta içi–hafta sonu ayrımı elde edilmiştir. Zaman temelli dinamiklerin modele doğrudan aktarılması hedeflenmiştir.

Etkileşim Özellikleri (Interactions) : Tek başına yeterince bilgi taşımayan değişkenler birleştirilerek daha güçlü sinyaller üretilmiştir.

- SPEED_X_UNITS: Hız limiti $\times$ araç sayısı ilişkisi modele tanıtılmıştır.
- SPEED_X_HOUR: Hız limiti $\times$ kaza saati etkileşimi eklenmiştir. Bu tür etkileşimler karmaşık örüntülerin yakalanmasında etkilidir.

2. Ön İşleme (Preprocessing)

Model öncesinde veriye uygulanan işlemler: (Bu işlemler tüm modeller için ortak olarak uygulanmıştır)

Sayısal Değişkenler : Eksik değer doldurma: *mean* , Ölçekleme: *StandardScaler*

Kategorik Değişkenler : Eksik değer doldurma: “MISSING” , Kodlama: *OneHotEncoder* (*handle_unknown="ignore"*)

3. Özellik Seçimi (Feature Selection)

Kodda Mutual Information tabanlı bir seçim uygulanmıştır. Bu işlem sadece 2. Senaryoda kullanılmıştır:

SelectKBest (Mutual Information – MI): En bilgilendirici 50 özellik seçilmiştir.

4. Boyut İndirgeme (Dimensionality Reduction)

Kodda boyut indirgeme yöntemi Truncated SVD kullanılarak uygulanmıştır. Bu işlem sadece Senaryo 3 de yapılmıştır:

TruncatedSVD (n_components=50): Birleştirilmiş sayısal + One-Hot kategorik özellikler 50 bileşene sıkıştırılmıştır.

Şule Kartal

Chicago trafik kazaları veri seti, çok sayıda sayısal ve kategorik değişken içermesi nedeniyle kapsamlı bir veri hazırlama sürecinden geçirilmiştir. Bu süreçte öncelikle veri seti genel olarak incelenmiş, yinelenen kayıtlar ve analiz sürecini olumsuz etkileyebilecek tutarsız gözlemler değerlendirilmiştir. Tarih ve zaman bilgileri standart bir formata dönüştürülerek veri bütünlüğü sağlanmıştır.

Eksik değer problemi, veri hazırlama sürecinin önemli bir aşamasını oluşturmuştur. Sayısal değişkenlerdeki eksik değerler, uç değerlerden daha az etkilenmesi nedeniyle medyan istatistiği kullanılarak doldurulmuştur. Kategorik değişkenlerde ise eksik gözlemler, veri setinde en sık görülen kategori (most frequent) ile tamamlanmıştır. Eksik oranı yüksek olan veya modelleme açısından bilgi değeri düşük olduğu değerlendirilen bazı sütunlar veri setinden çıkarılmıştır.

Zaman bilgisi içeren değişkenler doğrudan modele verilmek yerine, modelleme sürecine daha uygun hale getirilmesi amacıyla yıl, ay, gün ve saat gibi alt bileşenlerine ayrılmıştır. Bu dönüşüm sayesinde kazaların zamansal dağılımı daha ayrıntılı biçimde temsil edilebilmiştir.

Veri dönüştürme aşamasında, makine öğrenmesi algoritmalarının sayısal verilerle daha etkili çalışabilmesi için ölçeklendirme işlemleri uygulanmıştır. Sayısal değişkenler, ortalaması sıfır ve varyansı bir olacak şekilde StandardScaler kullanılarak standartlaştırılmıştır. Bu adım özellikle mesafeye dayalı ve doğrusal modellere sahip algoritmalar için model performansının daha kararlı hale gelmesini sağlamıştır.

Kategorik değişkenlerin sayısal forma dönüştürülmesi amacıyla One-Hot Encoding yöntemi kullanılmıştır. Bu yaklaşım sayesinde her kategori ayrı bir ikili (binary) değişken olarak temsil edilmiş ve algoritmaların kategorik bilgiyi doğrudan öğrenebilmesi mümkün hale getirilmiştir. Ortaya çıkan yüksek boyutlu ve seyrek (sparse) yapı, sonraki adımlarda özellik seçimi ve boyut indirgeme teknikleriyle ele alınmıştır.

Özellik seçimi aşamasında, hedef değişkenle ilişkisi düşük olan değişkenleri belirlemek amacıyla Mutual Information ve ANOVA F-test gibi filtre tabanlı yöntemler kullanılmıştır. Bu analizler sonucunda modele katkısı sınırlı olan özellikler elenmiştir. Ardından gömülü (embedded) yöntemler kapsamında L1 düzenleme yapısına sahip Linear SVC modeli kullanılarak, model performansına en fazla katkı sağlayan değişkenler belirlenmiştir.

Yüksek boyutluluk problemini azaltmak amacıyla boyut indirgeme süreci uygulanmıştır. Veri setinin büyük ölçüde one-hot encoded kategorik değişkenlerden oluşması nedeniyle PCA yerine, seyrek veri yapısına daha uygun olan Truncated SVD yöntemi tercih edilmiştir. Bu sayede veri boyutu düşürülmüş, bilgi kaybı minimum seviyede tutulurken modelin hesaplama maliyeti azaltılmıştır.

Tüm bu adımların sonunda; temizlenmiş, dönüştürülmüş, ölçeklendirilmiş ve modellemeye hazır bir veri seti elde edilmiştir. Hazırlanan bu veri seti, makine öğrenmesi modellerinin daha tutarlı, dengeli ve yorumlanabilir sonuçlar üretmesine olanak sağlamıştır.

Emine Esra Çetin

Bu bölümde çalışmada kullanılan “Traffic Crashes” veri seti için uygulanan veri hazırlama adımları ayrıntılı biçimde açıklanmaktadır. Süreç; veri temizleme, eksik değerlerin giderilmesi, veri dönüşümleri, özellik mühendisliği, özellik seçimi ve boyut indirgeme aşamalarını kapsamaktadır. Tüm ön işleme adımları, modelleme sürecinde veri sızıntısını (data leakage) önleyecek şekilde yalnızca eğitim verisi üzerinde öğrenilmiş ve test verisine aynı dönüşümler uygulanmıştır.

1. Özellik Mühendisliği (Feature Engineering)

Bu çalışmada modelleme öncesinde, yeni değişken üretiminden ziyade mevcut değişkenlerin korunarak veri kalitesinin artırılmasına odaklanan bir yaklaşım benimsenmiştir. Bu kapsamda, sınırlı sayıda etki alanı (domain) bilgisine dayalı düzenleme yapılmış, ancak yüksek kardinaliteye veya sızıntı riskine sahip değişkenler veri setinden çıkarılmıştır.

Etki Alanı (Domain) Tabanlı Düzenlemeler

Trafik kazası verisinin yapısına uygun olarak POSTED_SPEED_LIMIT değişkeni trafik mevzuatı dikkate alınarak kontrol edilmiştir. Negatif değerler veya gerçekçi olmayan hız sınırlarını temsil eden (0–90 aralığı dışındaki) gözlemler anomali olarak değerlendirilmiş ve veri setinden çıkarılmıştır. Bu işlem, modelin yalnızca gerçekçi trafik koşullarını temsil eden veriler üzerinden öğrenmesini sağlamak amacıyla uygulanmıştır.

Ayrıca, hedef değişkenle doğrudan ilişkili olan ve model performansını yapay olarak artırabilecek INJURIES ile ilişkili sütunlar veri sızıntısı riski nedeniyle veri setinden kaldırılmıştır. Bunun yanında; tarih, konum, sokak adı ve kimlik bilgisi içeren, yüksek kardinaliteye sahip veya ezberlemeye yol açabilecek değişkenler de modelleme sürecine dahil edilmemiştir. Bu sayede modelin ham veriyi ezberlemesi yerine genellenebilir örüntüler öğrenmesi hedeflenmiştir.

Bu adımlar sonucunda yeni özellikler türetilmemiş olsa da, trafik dinamiklerini daha doğru temsil eden, daha temiz ve güvenilir bir özellik uzayı elde edilmiştir.

Zaman Temelli Özellikler (Time-Based Features)

Kazaların tarih ve saat bilgilerine dayalı yeni zaman temelli özellikler (örneğin gün, ay, saat) türetilmemiştir. Tarih alanları yüksek kardinaliteye sahip olmaları ve veri sızıntısı riski taşımaları nedeniyle veri setinden çıkarılmıştır. Bu yaklaşım, modelin belirli zamanlara özgü örüntüleri ezberlemesini engelleyerek genelleme yeteneğini artırmayı amaçlamaktadır.

2. Ön İşleme (Preprocessing)

Projede kullanılan tüm modeller için ortak ve tutarlı bir ön işleme süreci uygulanmıştır. Sayısal değişkenlerdeki eksik değerler, uç değerlerden daha az etkilenmesi nedeniyle medyan (median) stratejisi kullanılarak doldurulmuştur. Ardından, özellikle doğrusal modellerde ölçek uyumunu sağlamak amacıyla StandardScaler ile ölçeklendirme işlemi gerçekleştirilmiştir.

Kategorik değişkenlerdeki eksik değerler ise bilgi kaybını önlemek amacıyla “MISSING” etiketiyle doldurulmuştur. Tüm kategorik değişkenler OneHotEncoder(handle_unknown="ignore") yöntemi ile kodlanmıştır. Bu sayede, eğitim aşamasında görülmeyen yeni kategoriler test aşamasında hata oluşturmadan modele dahil edilebilmiştir.

Tüm bu ön işleme adımları, Pipeline ve ColumnTransformer yapıları kullanılarak gerçekleştirilmiş, böylece eğitim ve test verileri üzerinde aynı dönüşümlerin tutarlı biçimde uygulanması sağlanmıştır.

3. Özellik Seçimi (Feature Selection)

Bu çalışmada özellik seçimi amacıyla filtre tabanlı bir yöntem olan SelectKBest kullanılmıştır. ANOVA F-testi (f_classif) ile sınıf ayırım gücü en yüksek olan özellikler belirlenmiş ve $k = 100$ olarak seçilmiştir. Bu işlem, özellikle One-Hot Encoding sonrasında oluşan yüksek boyutlu özellik uzayında daha anlamlı değişkenlerin modele dahil edilmesini sağlamak amacıyla uygulanmıştır.

SelectKBest yöntemi, ön işleme adımlarının bir parçası olarak model pipeline'ına entegre edilmiş ve yalnızca eğitim verisi üzerinden hesaplanarak veri sızıntısı riski engellenmiştir.

4. Boyut İndirgeme (Dimensionality Reduction)

Yüksek boyutlu ve seyrek (sparse) veri yapısına sahip One-Hot Encoding çıktıları için boyut indirgeme amacıyla TruncatedSVD yöntemi kullanılmıştır. Bu yöntemde bileşen sayısı $n_components = 50$ olarak belirlenmiştir. TruncatedSVD, veriyi daha düşük boyutlu bir temsile dönüştürerek hesaplama maliyetini azaltmış ve gürültüyü baskılamıştır.

Bu yöntem, özellikle SGD tabanlı sınıflandırıcılar ve Balanced Logistic Regression modellerinin pipeline'ına entegre edilerek, boyut indirgeme uygulanmış ve uygulanmamış modeller arasında performans karşılaştırmaları yapılmıştır.

Dilara Kurtul

Veri hazırlama süreci şu adımlardan oluşmaktadır:

Veri Yükleme ve Keşifsel Analiz: "Traffic_Crashes.csv" veri seti yüklenerek yaklaşık 300.000 satır ve çok sayıda sütundan oluşan ham yapı analiz edilmiştir. Veri setindeki sütun tipleri, bellek kullanımı ve eksik değerlerin genel dağılımı incelenerek veri profili çıkarılmıştır.

Mantıksal Tutarlılık ve Temizlik: Sayısal değişkenlerdeki hatalı girişleri ayıklamak adına mantıksal filtrelemeler uygulanmıştır. Örneğin, hız sınırı (POSTED_SPEED_LIMIT) değişkeninde 0 ile 80 mil/saat dışındaki uç veya imkansız değerler temizlenerek verinin gerçek dünya senaryolarına uygunluğu sağlanmıştır.

Eksik Değer Yönetimi: Eksik değerlerin oranı hesaplanmış ve bilgi içeriği çok düşük olan (örneğin %90'ın üzerinde boş olan WORK_ZONE_TYPE, DOORING_I gibi) sütunlar veri setinden tamamen çıkarılmıştır. Diğer sütunlar için uygun imputasyon stratejileri ön işleme hattına (pipeline) dahil edilmiştir.

Veri Sızıntısı (Data Leakage) Kontrolü ve Değişken Seçimi: Modelin başarısını yapay olarak artıran ve gerçek zamanlı tahmin anında elimizde olmayacak olan "yaralanma istatistikleri" (INJURIES_TOTAL, INJURIES_FATAL, INJURIES_INCAPACITATING vb.) ile konum bazlı gereksiz meta veriler veri setinden çıkarılmıştır. Bu sayede modelin sadece kaza anındaki çevresel faktörlere odaklanması sağlanmıştır.

Hedef Değişken ve Sınıf Dengesi: "MOST_SEVERE_INJURY" (En Şiddetli Yaralanma) hedef değişkeni olarak belirlenmiş ve LabelEncoder ile sayısal forma dönüştürülmüştür. Sınıflar arasındaki

belirgin dengesizlik tespit edilmiş; modelin azınlık sınıfları (ağır yaralanmalar) göz ardı etmemesi için `class_weight` parametresine ve macro metrik analizlerine öncelik verilmiştir.

Veri Setinin Bölünmesi: Veri seti; modelin eğitimi, hiperparametre optimizasyonu ve nihai performans ölçümü için üç aşamalı olarak ayrılmıştır. Toplam verinin %75'i eğitim, %20'si test ve %5'i doğrulama (validation) seti olarak stratified sampling yöntemiyle bölünerek sınıf dağılımının korunması sağlanmıştır.

Aykırı Değer ve Dağılım Analizi: Sayısal özellikler için kutu grafikleri (boxplot) ve histogramlar üzerinden dağılım incelemesi yapılmıştır. IQR (Interquartile Range) yöntemiyle aykırı değer oranları tespit edilmiştir. Ancak kazaların doğasındaki ekstrem durumların (yüksek hız vb.) ayırt edici bilgi taşıması nedeniyle bu değerler silinmemiş, standart ölçeklendirme ile modele uygun hale getirilmiştir.

Ön İşleme Hattı (Preprocessing Pipeline): Veri dönüşümü için iki farklı kanal oluşturulmuştur:

Sayısal Değişkenler: Eksik değerler için medyan (median) imputasyonu ve ardından verilerin aynı ölçeğe getirilmesi için `StandardScaler` uygulanmıştır.

Kategorik Değişkenler: Eksik değerler en sık tekrar eden değer (most frequent) ile doldurulmuş ve ardından `OneHotEncoder` ile ikili (binary) sütunlara dönüştürülmüştür.

Özellik Seçimi ve Boyut İndirgeme: Modelin karmaşıklığını azaltmak için `VarianceThreshold` ile düşük varyanslı (ayırt ediciliği az) değişkenler elenmiştir. Ardından, `SelectKBest` yöntemi ve "Mutual Information" kriteri kullanılarak hedef değişkenle en yüksek ilişkisi bulunan en anlamlı 50 özellik seçilmiştir.

Modelleme Yaklaşımı: Hazırlanan veriler üzerinde başlangıçta Linear SVC ve Logistic Regression gibi modeller test edilmiş; ardından Gradient Boosting ile performans karşılaştırması yapılmıştır. Sınıf dengesizliği altında en güvenilir "recall" ve "F1-score" değerlerini sunan modeller final raporu için temel alınmıştır.

YAĞMUR DEVECİ

Bu çalışmada özellik mühendisliği, veri setindeki ham değişkenleri model tarafından daha kolay öğrenilebilir ve açıklayıcı hâle getirmek amacıyla uygulanmıştır. Domain bilgisi, sayısal etkileşimler, kategorik dönüştürmeler ve zaman temelli türetilmeler kullanılarak veri setinin temsil gücü artırılmıştır. Boyut indirgeme aşamasında ise yüksek boyutlu ve redundant özelliklerin etkisini azaltmak için PCA yöntemi uygulanmış, veri setindeki varyansın %95'i korunarak modelin genellebilirliği ve hesaplama verimliliği iyileştirilmiştir. Ayrıca, veri işleme adımlarının tutarlılığını sağlamak ve eğitim-test verisi arasındaki bilgi sızıntısını (data leakage) önlemek amacıyla tüm süreç, Scikit-learn kütüphanesinin Pipeline ve ColumnTransformer mimarisi üzerine inşa edilmiştir.

1. Özellik Mühendisliği (Feature Engineering)

Veri setindeki mevcut değişkenlerden modelleme için anlamlı yeni özellikler türetilmiştir. Örneğin, CRASH_HOUR değişkeni üzerinden günün saatine göre kaza riskini yansıtan gruplar oluşturuldu. Sayısal değişkenlerin etkileşimlerinden, örneğin POSTED_SPEED_LIMIT ile ROAD_CONDITION çarpımı gibi, yeni sütunlar üretildi. Kategorik değişkenlerde ise gruplama ve özetleme yöntemleri kullanılarak WEATHER_CONDITION ve LIGHTING_CONDITION gibi değişkenlerin sınıf bazlı toplam ve oran değerleri hesaplandı. Bu sayede modelin öğrenme kapasitesini artıracak anlamlı özellikler elde edildi.

2. Ön İşleme (Preprocessing)

Eksik değerler sayısal sütunlarda medyan ile dolduruldu. Kategorik sütunlarda ise başlangıçta en sık değer atama yöntemi kullanılırken, geliştirilen yeni yapıda modelin eksiklik bilgisini de bir öznitelik olarak öğrenebilmesi için eksik veriler sabit bir "MISSING" etiketi ile doldurulmuştur. Mantıksal tutarlılık kontrolleri (Sanity Checks) uygulandı; örneğin POSTED_SPEED_LIMIT değerleri 0–90 aralığına çekildi ve dışındaki değerler temizlendi. Sayısal değişkenler StandardScaler ile standartlaştırıldı, kategorik değişkenler ise OneHotEncoder kullanılarak (bilinmeyen kategoriler göz ardı edilecek şekilde) kodlandı. Ayrıca, hedef değişkenle doğrudan ilişkili veya bilgi sızıntısına yol açabilecek sütunlar çıkarıldı.

3. Özellik Seçimi (Feature Selection)

Gereksiz veya düşük bilgi içeren değişkenler elimine edildi. RandomForest tabanlı SelectFromModel ve korelasyon analizi kullanılarak önemli ve redundant olmayan değişkenler seçildi. Bu adımlar modelin performansını artırırken hesaplama yükünü ve aşırı öğrenme riskini azalttı.

4. Boyut İndirgeme (Dimensionality Reduction)

Yüksek boyutlu veri setindeki redundant değişkenlerin etkisini azaltmak için PCA uygulandı ve varyansın %95'i korunarak boyut indirgeme yapıldı. Böylece hem modelin hesaplama maliyeti azaldı hem de çoklu korelasyon etkisi minimize edilerek genellebilirlik artırıldı.

7) MODELLEME

Kübra Beyza Aybar

Bu aşamada amaç, ön işlemeden geçirilen verinin farklı modelleme yaklaşımları ile eğitilerek performanslarının karşılaştırılmasıdır. Tüm modeller aynı preprocessing adımlarını içeren Pipeline yapısı içinde kurulmuş, böylece adil bir karşılaştırma sağlanmıştır. Performans değerlendirmesinde çok sınıflı problemler için uygun olan F1-macro metriği esas alınmıştır. Gerekli görülen modellerde hiperparametre optimizasyonu uygulanmıştır.

Çalışmada üç temel senaryonun yanı sıra, boosting ve ensemble tabanlı ek modeller de değerlendirilmiştir.

Senaryo 1: Baseline Model

İlk senaryo, hiçbir ek özellik seçimi veya boyut indirgeme işlemi eklenmeden, yalnızca ön işlemeden geçirilen verinin Decision Tree modeli ile eğitilmesi şeklindedir. Bu model, sonraki gelişmiş senaryolarla kıyaslama yapabilmek için referans noktası olarak seçilmiştir.

Decision Tree modeli, hem kategorik hem de sayısal değişkenlerle herhangi bir ek dönüştürme gerektirmeden doğal biçimde çalışabilmesi, değişkenler arasındaki karmaşık ve doğrusal olmayan ilişkileri kolaylıkla öğrenebilmesi ve yapısı gereği oldukça yüksek bir yorumlanabilirlik sunması nedeniyle tercih edilmiştir. Bu özellikleri sayesinde model, veri setinin temel yapısını anlamak ve sonraki gelişmiş senaryolarla karşılaştırma yapabilmek için uygun bir “baseline” yaklaşımı oluşturur.

Senaryo 2: Feature Selection (Mutual Information) + Decision Tree

Bu senaryoda preprocessing sonrası oluşan yüksek boyutlu veriden en bilgilendirici 50 özellik, Mutual Information tabanlı SelectKBest yöntemiyle seçilmiştir. Amaç, gürültülü veya düşük etkili değişkenleri elemektir.

Mutual Information tabanlı özellik seçimi, One-Hot Encoder sonrasında oluşan yüksek boyutlu veri yapısını sadeleştirmek ve daha anlamlı bir alt özellik kümesi elde etmek amacıyla kullanılmıştır. Bu sayede hem gereksiz ya da düşük etkili değişkenler elenmiş, hem de modelin daha hızlı çalışması ve daha iyi genelleme yapması hedeflenmiştir. Karar ağacı modeli değişmeden korunmuş, ancak modele verilen giriş verisi daha rafine ve bilgilendirici hale getirilmiştir.

Senaryo 3: Boyut İndirgeme (Truncated SVD) + Decision Tree

Üçüncü senaryoda, yüksek boyutlu ve özellikle One-Hot Encoder sonrasında oluşan seyrek veri yapısını daha kompakt bir forma dönüştürmek amacıyla Truncated SVD uygulanmıştır. Bu yöntem, özellikler arasındaki ilişkileri daha düşük boyutlu bir uzayda temsil ederek hem gürültüyü azaltmayı hem de modelin daha hızlı çalışmasını sağlamayı hedefler. Boyut indirgeme işlemi sonucunda elde edilen bu sıkıştırılmış ve daha düzenli veri temsili, Decision Tree modeline giriş olarak verilmiş ve böylece modelin performansının daha verimli bir biçimde değerlendirilmesi amaçlanmıştır.

Senaryo 4: LightGBM (Optuna ile Hiperparametre Optimizasyonu)

Bu senaryoda, boosting tabanlı LightGBM modeli kullanılmıştır. Modelin hiperparametreleri Optuna ile optimize edilmiş, değerlendirme Stratified K-Fold çapraz doğrulama ve F1-macro metriği üzerinden yapılmıştır. En iyi parametreler ile eğitilen model test verisi üzerinde detaylı olarak değerlendirilmiştir.

Senaryo 5: AdaBoost (GridSearchCV)

Bu senaryoda, temel öğrenici olarak Decision Tree kullanan AdaBoost modeli uygulanmıştır. Hiperparametreler GridSearchCV ile belirlenmiş ve en iyi model test seti üzerinde performans metrikleri ve karışıklık matrisi ile analiz edilmiştir.

Senaryo 6: Stacking Ensemble

Bu senaryoda, farklı öğrenme algoritmalarının güçlü yönlerini birleştirmeyi amaçlayan Stacking Ensemble yaklaşımı uygulanmıştır. İlk seviye (base learners) modeller olarak Decision Tree ve Logistic Regression kullanılmış, bu modellerin çıktıları ikinci seviye bir Logistic Regression modeli tarafından birleştirilmiştir.

Stacking yapısı sayesinde, farklı model türlerinin karar sınırları birlikte değerlendirilmiş ve tek bir modelin yakalayamayacağı örüntülerin öğrenilmesi amaçlanmıştır. Model, Pipeline yapısı içerisinde eğitilmiş ve test verisi üzerinde çok sınıflı performans metrikleri ile değerlendirilmiştir. Confusion matrix analizi ile özellikle sınıflar arası karışmalar detaylı olarak incelenmiştir.

Senaryo 7: Gradient Boosting Classifier

Son senaryoda, klasik **Gradient Boosting Classifier** modeli kullanılarak ensemble tabanlı bir başka yaklaşım test edilmiştir. Bu model, ardışık olarak eğitilen karar ağaçları ile hataları minimize etmeye odaklanır ve özellikle orta ölçekli veri setlerinde güçlü bir performans sunar.

Belirlenen sabit hiperparametreler ile eğitilen model, test seti üzerinde değerlendirilmiş ve diğer ensemble yöntemleri ile karşılaştırılmıştır. Elde edilen sonuçlar, tüm modellerin F1-macro skorları üzerinden görselleştirilerek karşılaştırmalı bir analiz yapılmıştır.

Şule Kartal

Bu çalışmada modelleme süreci, Chicago trafik kazaları veri setinin yapısını anlamak ve farklı makine öğrenmesi algoritmalarının performanslarını karşılaştırmak amacıyla yürütülmüştür. İlk aşamada doğrusal ve yorumlanabilir yapıları nedeniyle Logistic Regression ve Linear Support Vector Classifier (Linear SVC) modelleri uygulanmıştır. Bu modeller, veri hazırlama ve dönüşüm adımlarının ardından eğitilerek temel bir performans karşılaştırma düzeyi oluşturmuştur.

Model performansları, çok sınıflı ve sınıflar arası dengesizlik içeren veri yapısı dikkate alınarak doğruluk (accuracy), precision, recall ve macro F1 skoru metrikleri üzerinden değerlendirilmiştir. Özellikle macro ortalama metriklerin kullanılmasıyla, azınlık sınıfların model performansı üzerindeki etkisi dengeli bir biçimde analiz edilmiştir. Tüm metrikler model çıktıları üzerinden hesaplanmış ve karşılaştırmalı olarak raporlanmıştır.

Doğrusal modellerin ardından, veri setindeki doğrusal olmayan ilişkileri daha iyi yakalayabilmek amacıyla farklı model aileleri kullanılmıştır. Bu kapsamda Decision Tree, Random Forest ve boosting tabanlı modeller uygulanarak ağaç temelli yöntemlerin performansı incelenmiştir. Bu modeller, özellikle değişkenler arası etkileşimleri ve karmaşık karar sınırlarını yakalama yetenekleri açısından değerlendirilmiştir.

Buna ek olarak, derin öğrenme yaklaşımını temsil eden Multi-Layer Perceptron (MLP) modeli de çalışmaya dahil edilmiştir. MLP modeli, çok katmanlı yapısı sayesinde veri setindeki doğrusal olmayan örüntüleri öğrenmek üzere eğitilmiş ve diğer klasik makine öğrenmesi modelleriyle karşılaştırılmıştır. Böylece geleneksel yöntemler ile sinir ağı tabanlı yaklaşım arasındaki performans farkları analiz edilmiştir.

Ayrıca, kategorik değişkenleri doğal yapılarıyla işleyebilme avantajına sahip olan CatBoost modeli kullanılmıştır. CatBoost, özellikle one-hot encoding gerektirmeden kategorik özellikleri ele alabilmesi ve aşırı öğrenmeye karşı daha dirençli yapısı nedeniyle modele dahil edilmiştir. Bu modelin performansı, diğer ağaç tabanlı ve doğrusal modellerle karşılaştırmalı olarak değerlendirilmiştir.

Tüm modeller için en uygun yapılandırmaların belirlenmesi amacıyla GridSearchCV ve RandomizedSearchCV yöntemleri kullanılarak hiperparametre optimizasyonu gerçekleştirilmiştir. Bu süreçte, modellerin genelleme kabiliyetini artırmak ve aşırı öğrenmeyi önlemek amacıyla çapraz doğrulama (cross-validation) sistematik biçimde uygulanmıştır. Böylece her model için daha kararlı ve güvenilir performans sonuçları elde edilmiştir.

Modelleme sürecinde ayrıca, özellik seçimi ve boyut indirgeme adımlarının model performansına etkisi de değerlendirilmiştir. Seçilmiş özellikler ve Truncated SVD ile indirgenmiş veri temsilleri kullanılarak modeller yeniden eğitilmiş; elde edilen sonuçlar, tam özellik setiyle eğitilen modellerle karşılaştırılmıştır. Bu karşılaştırmalar sayesinde model karmaşıklığı ile tahmin başarımı arasındaki denge analiz edilmiştir.

Son olarak, modeller yalnızca tek bir performans metriği üzerinden değil; ROC eğrileri, Precision–Recall eğrileri ve sınıf bazlı hata analizleri ile detaylı biçimde değerlendirilmiştir. Bu görselleştirmeler, modellerin farklı sınıflar üzerindeki davranışlarını açık biçimde ortaya koymuş ve elde edilen sonuçların yorumlanabilirliğini artırmıştır.

Bu kapsamlı modelleme süreci sonucunda, doğrusal modellerden derin öğrenme ve gelişmiş boosting yöntemlerine kadar farklı algoritmaların güçlü ve zayıf yönleri sistematik olarak karşılaştırılmış; veri yapısına en uygun modeller belirlenerek çalışmanın sonuç bölümüne temel oluşturacak güvenilir çıktılar elde edilmiştir.

Emine Esra Çetin

Bu bölümde, trafik kazalarında yaralanma şiddetinin tahmin edilmesi amacıyla geliştirilen makine öğrenmesi modelleri, kullanılan algoritmalar, modelleme stratejileri ve karşılaştırma yaklaşımı ayrıntılı biçimde açıklanmaktadır. Modelleme sürecinde farklı sınıflandırma algoritmaları denenmiş, sınıf dengesizliği problemi dikkate alınmış ve tüm modeller aynı ön işleme adımlarını içeren pipeline yapıları içerisinde eğitilmiştir.

1. Problem Tanımı ve Veri Bölme

Çalışma, çok sınıflı bir sınıflandırma problemi olarak ele alınmıştır. Hedef değişken, trafik kazası sonucunda oluşan yaralanma şiddetini temsil etmektedir. Veri seti, model performansının objektif biçimde değerlendirilebilmesi amacıyla eğitim (train) ve test (test) olmak üzere ikiye ayrılmıştır. Bölme işlemi sırasında sınıf dağılımının korunması için **stratified split** yaklaşımı kullanılmıştır.

2. Modelleme Stratejisi

Modelleme sürecinde, hem doğrusal hem de ağaç tabanlı algoritmalar kullanılarak farklı öğrenme yaklaşımlarının performansları karşılaştırılmıştır. Tüm modeller, veri sızıntısını önlemek ve ön işleme adımlarının tutarlılığını sağlamak amacıyla **Pipeline** yapısı içerisinde oluşturulmuştur. Böylece eksik değer doldurma, ölçekleme, kodlama, özellik seçimi ve boyut indirgeme gibi adımlar modelin ayrılmaz bir parçası hâline getirilmiştir.

Sınıf dengesizliği problemini azaltmak amacıyla, uygun modellerde **class_weight="balanced"** parametresi kullanılarak sınıflar arası ağırlıklandırma yapılmıştır.

3. Kullanılan Modeller

3.1. Passive-Aggressive Classifier

İlk model olarak, özellikle büyük veri setlerinde hızlı öğrenme kabiliyetiyle bilinen **Passive-Aggressive Classifier** kullanılmıştır. Bu algoritma, çevrim içi (online) öğrenme mantığıyla çalışmakta ve her yeni örnekle birlikte model ağırlıklarını güncelleyebilmektedir. Model, doğrusal bir sınıflandırıcı olup yüksek boyutlu veri setlerinde etkili sonuçlar verebilmektedir.

Passive-Aggressive Classifier, One-Hot Encoding sonrası oluşan yüksek boyutlu veri yapısına uygun olması ve hızlı eğitim süresi nedeniyle temel (baseline) modellerden biri olarak değerlendirilmiştir.

3.2. Dengelenmiş Lojistik Regresyon (Balanced Logistic Regression)

İkinci model olarak, **class_weight="balanced"** parametresi kullanılarak dengelenmiş bir **Logistic Regression** modeli eğitilmiştir. Bu yaklaşım, sınıf dengesizliğinin bulunduğu veri setlerinde azınlık sınıflarının model tarafından ihmal edilmesini önlemeyi amaçlamaktadır.

Lojistik regresyon modeli, doğrusal bir karar sınırı oluşturması nedeniyle yorumlanabilirliği yüksek bir modeldir. Bu nedenle çalışmada hem performans hem de açıklanabilirlik açısından önemli bir referans modeli olarak kullanılmıştır.

Bu model, hem doğrudan özellik seçimi uygulanmış hâliyle hem de **TruncatedSVD** ile boyut indirgeme entegre edilmiş pipeline yapısıyla test edilmiştir.

3.3. Histogram Tabanlı Gradient Boosting (HistGradientBoostingClassifier)

Doğrusal modellerin yanı sıra, doğrusal olmayan ilişkileri daha iyi yakalayabilmek amacıyla **HistGradientBoostingClassifier** kullanılmıştır. Bu algoritma, klasik Gradient Boosting yaklaşımının histogram tabanlı optimize edilmiş bir versiyonudur ve büyük veri setlerinde daha hızlı çalışmaktadır.

Model, varsayılan hiper-parametre ayarlarıyla eğitilmiş ve erken durdurma (early stopping) mekanizması aktif hâle getirilmemiştir. Bu tercih, çalışmanın odağının hiper-parametre optimizasyonundan ziyade model türlerinin karşılaştırılması olması nedeniyle yapılmıştır.

3.4. Extra Trees Classifier (Extremely Randomized Trees)

Son model olarak, rastgeleliğin artırıldığı bir ağaç tabanlı yöntem olan **ExtraTreesClassifier** kullanılmıştır. Bu algoritma, karar ağaçlarının bölünme noktalarını tamamen rastgele seçerek varyansı azaltmayı ve genelleme performansını artırmayı hedefler.

Extra Trees modeli, doğrusal olmayan yapıları güçlü şekilde modelleyebilmesi ve özellik etkileşimlerini otomatik olarak öğrenebilmesi nedeniyle çalışmada önemli bir karşılaştırma modeli olarak ele alınmıştır.

4. Pipeline Yapısı ve Entegrasyon

Tüm modeller, aşağıdaki adımları içeren **Pipeline** yapısı içerisinde oluşturulmuştur:

- Sayısal değişkenler için medyan ile eksik değer doldurma
- Kategorik değişkenler için “MISSING” etiketi ile doldurma
- One-Hot Encoding
- StandardScaler ile ölçekleme
- SelectKBest (k = 100, f_classif) ile özellik seçimi
- Gerekli modeller için TruncatedSVD (n_components = 50) ile boyut indirgeme
- Sınıflandırma algoritması

Bu yapı sayesinde, tüm ön işleme adımları yalnızca eğitim verisi üzerinden öğrenilmiş ve test verisine aynı dönüşümler uygulanmıştır.

5. Hiper-Parametre Ayarlama ve Sınıf Dengesizliği Yaklaşımı

Bu çalışmada kapsamlı bir hiper-parametre arama stratejisi (Grid Search, Random Search veya Bayesyen optimizasyon) uygulanmamıştır. Modeller, literatürde yaygın olarak kullanılan ve kararlı sonuçlar üreten varsayılan veya sabit hiper-parametreler ile eğitilmiştir. Erken durdurma (early stopping) mekanizması herhangi bir modelde kullanılmamıştır.

Sınıf dengesizliği problemiyle mücadelede, veri dağılımını yapay olarak değiştiren yeniden örnekleme yöntemleri (SMOTE, yetersiz örnekleme) tercih edilmemiştir. Bunun yerine, özellikle Lojistik Regresyon modelinde `class_weight="balanced"` parametresi kullanılarak sınıf ağırlıklandırma yaklaşımı benimsenmiştir. Sınıflandırma karar eşiği (threshold) üzerinde ayrıca bir ayarlama yapılmamıştır.

6. Model Karşılaştırma Yaklaşımı

Modeller, aynı veri bölme ve ön işleme koşulları altında eğitilerek karşılaştırılmıştır. Performans değerlendirmesinde yalnızca doğruluk (accuracy) metriğine değil, sınıf dengesizliği nedeniyle sınıf bazlı başarıyı yansıtan değerlendirme metriklerine de odaklanılmıştır. Bu yaklaşım, modelin yalnızca baskın sınıfı değil, tüm sınıfları ne ölçüde doğru tahmin edebildiğini analiz etmeyi amaçlamaktadır.

Dilara Kurtul

Bu çalışmada, trafik kazalarındaki yaralanma şiddetini sınıflandırmak amacıyla doğrusal ve doğrusal olmayan farklı makine öğrenmesi yaklaşımları test edilmiştir. Modelleme süreci, basit bir başlangıç noktasından (baseline) karmaşık ve düzenlenleştirilmiş modellere doğru şu aşamalarda gerçekleştirilmiştir:

- 1. Baseline Model (Temel Doğrusal Yaklaşım):** İlk aşamada, veri setinin lineer ayrılabilirliğini test etmek amacıyla Linear SVC modeli temel alınmıştır. Bu aşamada kurulan pipeline; sayısal değişkenler için medyan imputasyonu ve standart ölçekleme, kategorik değişkenler için ise en sık görülen değer ile imputasyon ve OneHot kodlama adımlarını içermektedir.
- 2. Sınıf Dengesizliği ile Mücadele:** Hedef değişkendeki sınıfların (örneğin "Ölümcül Kaza" ile "Yaralanmasız Kaza") frekansları arasındaki aşırı farkı dengelemek için Linear SVC modelinde `class_weight='balanced'` parametresi kullanılmıştır. Bu sayede modelin azınlık sınıflara (ağır yaralanmalar) daha fazla ağırlık vererek öğrenmesi sağlanmıştır.
- 3. Özellik Seçimi ve Gürültü Azaltma (FS + VT):** Modelin performansını artırmak ve gereksiz özelliklerden arındırmak için iki aşamalı bir filtreleme uygulanmıştır:
 - VarianceThreshold: Varyansı 0.01'den düşük olan (neredeyse sabit değer içeren) etkisiz özellikler elenmiştir.
 - SelectKBest: *Mutual Information* kriteri kullanılarak hedef değişkenle en yüksek istatistiksel ilişkiye sahip 50 özellik seçilmiştir.
- 4. Doğrusal Olmayan Yaklaşım (Gradient Boosting):** Veri setindeki karmaşık ve doğrusal olmayan etkileşimleri yakalamak amacıyla Gradient Boosting Classifier eğitilmiştir. Bu

model, ardışık karar ağaçları kullanarak tahmin hatalarını minimize etmeyi hedeflemiş ve genel doğruluk (accuracy) bazında en yüksek skoru elde etmiştir.

5. **L1 Düzenleştirilmeli Linear SVC (Final Model):** Yüksek boyutlu verilerde (One-Hot sonrası oluşan çok sayıda sütun) aşırı öğrenmeyi (overfitting) engellemek ve özellik seçimi işlemini modelin içine gömmek amacıyla L1-Regularized Linear SVC (`penalty='l1'`) kullanılmıştır. Bu model, katsayıları sıfıra yaklaştırarak "seyrek" (sparse) bir model oluşturmuş ve hem hızı hem de yorumlanabilirliği artırmıştır.
6. **Performans Karşılaştırması ve Model Seçimi:** Modellerin başarısı sadece doğruluk (accuracy) üzerinden değil; precision, recall, macro F1-score ve karmaşıklık matrisi (confusion matrix) üzerinden değerlendirilmiştir.
 - Bulgu: Gradient Boosting modeli en yüksek genel doğruluğu verse de, kritik önem taşıyan "Fatal" (Ölümcül) ve "Incapacitating Injury" (Ağır Yaralanma) sınıflarında düşük performans göstermiştir.
 - Karar: Sınıf dengesizliği altında azınlık sınıflar için daha tutarlı "recall" (geri çağırım) değerleri sunan ve güvenlik açısından daha dengeli sonuçlar üreten L1 düzenleştirilmeli Linear SVC modeli projenin nihai yaklaşımı olarak tercih edilmiştir.

YAĞMUR DEVECİ

1. Baseline (Temel) Modeller

Modelleme sürecine, veri setinin temel yapısını değerlendirmek amacıyla basit base modellerle başlanmıştır. Bu aşamada Logistic Regression ve Random Forest kullanılarak temel doğruluk ve performans ölçütleri elde edilmiştir. Bu modeller, ileri adımlarda uygulanacak yöntemlerin etkinliğini karşılaştırmak için bir referans noktası sağlamaktadır.

2. Feature Selection (Özellik Seçimi) + Base Modeller

İkinci aşamada, modelin gereksiz veya düşük bilgi içeren özelliklerden etkilenmesini önlemek için RandomForestClassifier tabanlı SelectFromModel yöntemiyle özellik seçimi uygulanmıştır. Elde edilen seçilmiş özellikler üzerinde Logistic Regression ve Random Forest modelleri yeniden eğitilmiş, validation set performansları ölçülmüştür. Bu adım, modelin hem hesaplama verimliliğini artırmış hem de aşırı öğrenme riskini azaltmıştır.

3. PCA (Temel Bileşen Analizi) + Base Modeller

Üçüncü aşamada boyut indirgeme amacıyla PCA uygulanmış ve veri setindeki varyansın %95'i korunarak boyut düşürülmüştür. Bu boyut indirgeme sonrası elde edilen veriler üzerinde Logistic Regression ve Random Forest modelleri tekrar çalıştırılmış ve validation performansları karşılaştırılmıştır. Bu adım, yüksek boyutlu veri setinde redundant (gereksiz/tekrarlayan) değişkenlerin etkisini azaltmıştır.

4. Feature Selection + PCA + Base Modeller

Dördüncü aşamada hem özellik seçimi hem de PCA adımları birleştirilerek, veri seti önce önemli özellikler seçilmiş, ardından PCA ile boyut indirgeme yapılmıştır. Bu dönüştürülmüş veri üzerinde Logistic Regression ve Random Forest modelleri eğitilmiş, validation ve test setlerinde performansları ölçülmüştür. Bu kombinasyon, hem modelin öğrenme kapasitesini artırmış hem de genellebilirliği iyileştirmiştir.

5. Sınıf Dengesizliği Stratejisi

Tüm modellerde, hedef değişkenin sınıf dağılımı dengesiz olduğu için `class_weight='balanced'` parametresi kullanılmıştır. Bu sayede azınlık sınıflarının tahmin edilme oranı artırılmış ve modelin genel performansı dengelenmiştir.

6. İleri Seviye Topluluk Öğrenmesi (Ensemble Learning) Modelleri

Mevcut temel modellerin başarısını daha da yukarı taşımak amacıyla, projeye Gradient Boosting tabanlı ileri seviye algoritmalar olan XGBoost (Extreme Gradient Boosting) ve LightGBM (Light Gradient Boosting Machine) dahil edilmiştir. Bu modeller:

- Hata fonksiyonlarını (loss function) gradyan inişi (gradient descent) ile optimize ederek daha hassas tahminler yapabilmekte,
- Özellikle kategorik değişkenlerin yoğun olduğu ve karmaşık ilişkilerin bulunduğu bu veri setinde, temel modellere kıyasla daha yüksek doğruluk (Accuracy) ve F1 skorları üretmektedir.

7. Hiperparametre Optimizasyonu ve Model Tuning

XGBoost ve LightGBM modellerinin performansını maksimize etmek ve ezberlemeyi (overfitting) önlemek için GridSearchCV yöntemi kullanılmıştır. Her iki model için de:

- Ağaç sayısı (`n_estimators`),
- Öğrenme oranı (`learning_rate`),
- Maksimum derinlik (`max_depth`) gibi kritik hiperparametreler sistematik olarak taranmış ve Çapraz Doğrulama (Cross-Validation) skorlarına göre en iyi parametre setleri belirlenerek final modeller oluşturulmuştur.

8. Bütünleşik Pipeline Mimarisi

Veri sızıntısını (data leakage) engellemek ve modelin üretim ortamına (production) uygunluğunu sağlamak adına; veri ön işleme (imputation, scaling, encoding) ve modelleme adımları tek bir Scikit-learn Pipeline yapısı altında birleştirilmiştir. Bu sayede ham veri, manuel müdahale gerektirmeden uçtan uca işlenerek tahmin üretilebilir hale getirilmiştir.

8. DEĞERLENDİRME

Kübra Beyza Aybar

Model performansını daha sağlıklı değerlendirebilmek amacıyla Accuracy metriğine ek olarak F1 Macro, Recall Macro ve Precision Macro kullanılmıştır. Bu metrikler, özellikle sınıf dengesizliğinin bulunduğu çok sınıflı problemlerde modelin tüm sınıfları ne ölçüde öğrendiğini daha doğru biçimde yansıtmaktadır. Tüm senaryolarda aynı train-test bölünmesi kullanılmış, preprocessing adımları yalnızca eğitim verisi üzerinde fit edilerek veri sızıntısı (data leakage) önlenmiştir. Hata analizi kapsamında tüm modeller için karışıklık matrisleri incelenmiştir.

Elde edilen sonuçlara göre baseline Decision Tree modeli, Accuracy açısından en yüksek değeri üretmiştir. Mutual Information tabanlı Feature Selection uygulanan senaryoda Accuracy bir miktar düşmesine rağmen F1 Macro ve Recall Macro değerlerinin artması, modelin sınıf dengesizliğini daha iyi yönettiğini ve daha dengeli bir performans sunduğunu göstermiştir. Truncated SVD kullanılan senaryoda ise boyut indirgeme sırasında oluşan bilgi kaybı nedeniyle tüm performans metriklerinde düşüş gözlemlenmiştir.

Gelişmiş modelleme aşamasında uygulanan LightGBM (Optuna ile optimize edilmiş), AdaBoost (GridSearchCV), Gradient Boosting ve Stacking Ensemble modelleri, baseline yaklaşımlara kıyasla özellikle F1 Macro metriğinde daha dengeli ve kararlı sonuçlar üretmiştir. Bu modeller, sınıflar arası hataları azaltarak genel genelleme başarısını artırmıştır.

Genel değerlendirme sonucunda; Accuracy açısından en iyi model GradientBoosting,, denge ve genelleme başarısı açısından en etkili yaklaşım LightGBM, en zayıf performans ise Truncated SVD senaryosu olarak belirlenmiştir.

	Stage	Model	Accuracy	F1 Macro	Recall Macro	Precision Macro
0	Base Model	DecisionTree	0.652517	0.373602	0.374615	0.372964
1	Feature Selection	DecisionTree	0.637100	0.382338	0.400420	0.386226
2	PCA / Dim. Red.	DecisionTree	0.635800	0.361568	0.362347	0.361097

	Stage	Model	Accuracy	F1 Macro	Recall Macro	Precision Macro
0	Final Models	LightGBM	0.659983	0.417735	0.457785	0.418773
1	Final Models	AdaBoost	0.630500	0.395055	0.473931	0.424263
2	Final Models	GradientBoosting	0.726683	0.387411	0.401951	0.488495

Şule Kartal

Bu projede model performansının güvenilir ve karşılaştırılabilir biçimde ölçülmesi amacıyla çok aşamalı bir değerlendirme tasarımı uygulanmıştır. Öncelikle veri seti, modellerin genelleme kabiliyetini değerlendirebilmek için eğitim ve test alt kümelerine ayrılmıştır. Eğitim verisi üzerinde ise, hem basit hem de karmaşık modellerin farklı veri bölünmelerine karşı kararlılığını analiz etmek amacıyla çapraz doğrulama (cross-validation) kullanılmıştır.

Model değerlendirme sürecinde, veri setinin sınıflar arası dengesiz yapısı dikkate alınarak doğruluk (accuracy) metriğinin tek başına yeterli olmadığı kabul edilmiştir. Bu nedenle performans analizi; macro F1 skoru, precision ve recall metrikleri temel alınarak gerçekleştirilmiştir. Macro ortalama yaklaşımı sayesinde her sınıfın değerlendirmeye eşit katkı sağlaması hedeflenmiş, özellikle azınlık sınıflar üzerindeki model başarımı daha adil biçimde analiz edilmiştir. Buna ek olarak, modellerin sınıf bazlı hata dağılımlarını incelemek amacıyla karışıklık matrisleri (confusion matrices) kullanılmıştır.

Belirlenen değerlendirme metrikleri; doğrusal modeller (Logistic Regression, Linear SVC), ağaç tabanlı ve boosting yaklaşımları (Decision Tree, Random Forest, boosting tabanlı modeller), derin öğrenme yaklaşımını temsil eden Multi-Layer Perceptron (MLP) ve kategorik değişkenleri doğal yapısıyla ele alabilen CatBoost modeli için ayrı ayrı hesaplanmış ve karşılaştırmalı olarak analiz

edilmiştir. Bu sayede farklı model ailelerinin aynı veri seti üzerindeki performansları tutarlı bir çerçevede değerlendirilmiştir.

Karmaşık modeller için değerlendirme süreci yalnızca genel performans skorlarıyla sınırlı tutulmamıştır. Özellikle Random Forest, boosting tabanlı modeller ve CatBoost için sınıf bazlı tahmin davranışları incelenmiş; bu modellerin azınlık sınıfları yakalama başarısı macro F1, precision ve recall değerleri üzerinden analiz edilmiştir. Benzer şekilde MLP modeli, doğrusal olmayan örüntüleri öğrenme kapasitesi açısından diğer modellerle karşılaştırılmış ve performans farklılıkları değerlendirilmiştir.

Değerlendirme sürecinde ayrıca, veri ön işleme adımlarının model performansına etkisi sistematik biçimde takip edilmiştir. Özellik seçimi ve boyut indirgeme (feature selection ve dimensionality reduction) uygulandıktan sonra tüm modeller yeniden eğitilmiş; elde edilen performans sonuçları, ham özellik setiyle eğitilen modellerle karşılaştırılmıştır. Bu karşılaştırma, özellikle karmaşık modellerde gereksiz özelliklerin elenmesinin performans ve kararlılık üzerindeki etkisini ortaya koymuştur.

Son aşamada, tüm modeller hem ham veri hem de dönüştürülmüş veri temsilleri kullanılarak test edilmiş; elde edilen değerlendirme sonuçları doğrultusunda macro F1 skoru en yüksek, sınıflar arası performansı en dengeli ve farklı veri bölünmelerinde en tutarlı sonuçları veren model yapısı nihai model adayı olarak belirlenmiştir. Bu çok aşamalı değerlendirme yaklaşımı, hem basit hem de karmaşık modellerin güçlü ve zayıf yönlerinin açık biçimde karşılaştırılmasını sağlamış ve çalışmanın sonuçlarının güvenilirliğini artırmıştır.

	Grup	Model	Accuracy	Balanced Acc	Precision (Macro)	Recall (Macro)	F1 (Macro)	F1 (Weighted)
0	Base	MI + DecisionTree	0.642115	0.402233	0.387987	0.402233	0.386035	0.662087
1	Base	LogReg (Base)	0.610881	0.510873	0.416724	0.510873	0.381703	0.642361
2	Base	SVD + DecisionTree	0.636148	0.363951	0.362663	0.363951	0.363170	0.638162
3	Karmaşık	MLP	0.711186	0.397833	0.425608	0.397833	0.390491	0.698691
4	Karmaşık	CatBoost	0.612614	0.498795	0.416380	0.498795	0.384213	0.646567

Emine Esra Çetin

Bu bölümde geliştirilen sınıflandırma modellerinin performansı, notebook içerisinde test (validation) veri kümesi üzerinde hesaplanan çıktı metrikleri kullanılarak değerlendirilmiştir. Tüm modeller, aynı veri bölme stratejisi ve aynı ön işleme adımları altında eğitilmiş ve test edilmiştir. Böylece elde edilen performans değerlerinin doğrudan karşılaştırılabilir olması sağlanmıştır.

Değerlendirme sürecinde, sınıf dengesizliği bulunan veri setinin yapısı dikkate alınarak yalnızca doğruluk (accuracy) metriğiyle yetinilmemiş; bunun yerine precision, recall ve F1-score gibi sınıf bazlı başarıyı daha iyi yansıtan metrikler de analiz edilmiştir. Tüm metrikler, classification_report çıktıları üzerinden weighted (ağırlıklı) ortalama alınarak raporlanmıştır.

Doğrulama (Validation) Protokolü

Modellerin değerlendirilmesinde, veri seti stratified train/test split yöntemiyle eğitim ve test kümelerine ayrılmıştır. Bu yaklaşım sayesinde hedef değişkendeki sınıf dağılımı hem eğitim hem de test kümesinde korunmuştur. Çapraz doğrulama (k-fold CV) veya zaman serisi tabanlı doğrulama yöntemleri bu çalışmada kullanılmamıştır.

Veri sızıntısını önlemek amacıyla, eksik değer doldurma, ölçekleme, kategorik kodlama, özellik seçimi ve boyut indirgeme adımlarının tamamı Pipeline yapısı içerisinde tanımlanmış ve yalnızca eğitim verisi üzerinde öğrenilmiştir. Test verisi üzerinde herhangi bir ek öğrenme yapılmadan doğrudan tahmin üretilmiştir.

Kullanılan Değerlendirme Metrikleri

Notebook'ta her model için aşağıdaki metrikler hesaplanmıştır:

- Accuracy
- Precision (weighted)
- Recall (weighted)
- F1-Score (weighted)

Ağırlıklı ortalama kullanılması, baskın sınıfların değerlendirmeyi tek başına domine etmesini engellemek ve azınlık sınıfların performansını da hesaba katmak amacıyla tercih edilmiştir.

Hata Analizi (Confusion Matrix)

Her model için karışıklık matrisi (confusion matrix) oluşturulmuş ve sınıflar arası yanlış sınıflandırmalar ayrıntılı olarak incelenmiştir. Karışıklık matrisleri sayesinde, modellerin hangi sınıfları birbirleriyle karıştırdığı ve hata yoğunluğunun hangi sınıflarda toplandığı gözlemlenmiştir. Bu analiz, özellikle accuracy değeri benzer olan modeller arasındaki farkların yorumlanmasında önemli rol oynamıştır.

Aşağıdaki tabloda, test (validation) kümesi üzerinde elde edilen gerçek çıktı metrikleri karşılaştırmalı olarak sunulmaktadır. Değerler, her model için hesaplanan weighted ortalama sonuçları temsil etmektedir.

	Stage	Model	Accuracy	F1 weighted	Recall weighted	Precision weighted
0	Base Model	Passive-Aggressive Classifier	0.55	0.60	0.55	0.71
1	Base Model	Balanced Logistic Regression	0.61	0.64	0.61	0.72
2	Advanced Model	HistGradientBoostingClassifier	0.68	0.70	0.68	0.73
3	Advanced Model	ExtraTreesClassifier	0.66	0.69	0.66	0.73

Sonuçların Ayrıntılı Yorumu

Passive-Aggressive Classifier modeli, hızlı eğitim süresine rağmen test kümesinde en düşük **accuracy** ve **F1-score** değerlerini üretmiştir. Bu durum, modelin doğrusal yapısının ve çevrimiçi öğrenme yaklaşımının, karmaşık ve doğrusal olmayan özellik etkileşimlerini yeterince yakalayamamasından kaynaklanmaktadır.

Balanced Logistic Regression modeli, sınıf ağırlıklandırma stratejisi sayesinde Passive-Aggressive modele kıyasla daha dengeli sonuçlar üretmiştir. Özellikle recall ve F1-score değerlerindeki artış, azınlık sınıfların model tarafından daha iyi temsil edildiğini göstermektedir. Bununla birlikte, doğrusal karar sınırı nedeniyle performans artışı sınırlı kalmıştır.

HistGradientBoostingClassifier modeli, tüm metriklerde en yüksek değerlere ulaşarak çalışmadaki **en başarılı model** olmuştur. Bu modelin başarısı, doğrusal olmayan ilişkileri ve özellik etkileşimlerini

etkili biçimde öğrenebilmesine bağlanmaktadır. Özellikle F1-score değerinin yüksek olması, modelin sınıf dengesizliğine rağmen tutarlı tahminler üretebildiğini göstermektedir.

ExtraTreesClassifier modeli, HistGradientBoosting'e oldukça yakın performans sergilemiş; ancak F1-score ve accuracy değerleri bakımından bir miktar geride kalmıştır. Buna rağmen, doğrusal modellere kıyasla belirgin bir performans artışı sağlamış ve güçlü bir alternatif model olarak değerlendirilmiştir.

Dilara Kurtul

Bu çalışmada modellerin performansı sadece genel doğruluk (accuracy) üzerinden değil, sınıf bazlı metrikler (precision, recall, F1-score) ve karmaşıklık matrisleri (confusion matrix) üzerinden detaylıca analiz edilmiştir. Özellikle veri setindeki sınıf dengesizliği, "macro" ortalamalı metriklerin değerlendirmede ana kriter olarak seçilmesini zorunlu kılmıştır.

- Metrikler ve Metodoloji:** Modelin başarısını ölçmek için her sınıfın kendi içindeki başarısını gösteren hassasiyet (precision) ve duyarlılık (recall) değerleri incelenmiştir. Kazaların ciddiyetini tahmin etme probleminde, özellikle ağır yaralanmalı (Fatal ve Incapacitating) vakaların atlanmaması (yüksek recall) kritik önem taşıdığından, değerlendirmeler bu perspektifle yapılmıştır.
- Base Model ve Özellik Seçimi Performansı:**
 - Baseline Linear SVC:** Başlangıç modelinde "NO INDICATION OF INJURY" (Yaralanmasız) gibi baskın sınıflarda yüksek başarı elde edilirken, azınlık sınıfların tahmin başarısı düşük kalmıştır.
 - Feature Selection (FS) + VarianceThreshold (VT):** Özellik seçimi ve düşük varyanslı değişkenlerin elenmesi, modelin genel doğruluğunda veya Macro F1 skorunda (yaklaşık 0.40 seviyelerinde) beklenen büyük sıçramayı yaratmamıştır. Özellikle "INCAPACITATING INJURY" sınıfı, veri setindeki ayırt edici özelliklerin azlığı ve sınıfların birbirine yakınlığı nedeniyle model tarafından en çok karıştırılan sınıf olmuştur.
- Modeller Arası Karşılaştırmalı Analiz:**
 - Gradient Boosting (Doğruluk Odaklı):** Test sonuçlarına göre Gradient Boosting modeli en yüksek genel doğruluk (accuracy) değerine ulaşmıştır. Ancak yapılan derinlemesine analizde, bu başarının büyük oranda veri setindeki çoğunluk sınıfı (yaralanmasız kazalar) doğru tahmin etmesinden kaynaklandığı görülmüştür. "FATAL" ve "INCAPACITATING" gibi kritik sınıflarda ise geri çağırım (recall) oranları istenen seviyede gerçekleşmemiştir.
 - LinearSVC (Denge Odaklı):** L1 düzenlileştirmeli LinearSVC modeli, genel doğruluğu Gradient Boosting'e göre bir miktar düşük olsa da, azınlık sınıfları öğrenme ve sınıflar arası dengeyi koruma konusunda daha kararlı bir duruş sergilemiştir. Macro metrikler baz alındığında, doğrusal modellerin bu karmaşık veri yapısında daha "güvenilir" bir referans sunduğu saptanmıştır.
- Sınıf Bazlı Bulgular:**
 - FATAL:** Model, veri setinde nadir bulunmasına rağmen ölümcül kazaları belirli bir oranda yakalayabilmiştir.
 - NO INDICATION OF INJURY:** Verinin en büyük kısmını oluşturan bu sınıfta modeller %90'ın üzerinde F1 skoruyla stabil bir performans göstermiştir.

- **Karmaşıklık Matrisi Analizi:** Hataların çoğunlukla birbirine yakın yaralanma şiddetleri (örneğin "Reported, Not Evident" ile "Non-Incapacitating") arasında gerçekleştiği, bunun da kaza raporlarındaki subjektif tanımlardan kaynaklanabileceği değerlendirilmiştir.

Sonuç: Çalışma sonucunda, yalnızca doğruluk (accuracy) değerine odaklanmanın yanıltıcı olabileceği; trafik güvenliği gibi kritik bir alanda azınlık sınıfları ve macro metrikleri optimize eden modellerin tercih edilmesi gerektiği görülmüştür. Bu bağlamda, Linear SVC tabanlı modellerin, karmaşık ensemble yöntemlerine (Gradient Boosting gibi) kıyasla sınıf dengesizliği altında daha tutarlı ve yorumlanabilir sonuçlar ürettiği sonucuna varılmıştır.

=== TEST SONUÇLARI (macro) ===

	model	accuracy	precision	recall	f1 score
0	Baseline (LinearSVC)	0.683	0.427	0.488	0.402
1	Baseline + FS&VT (LinearSVC)	0.683	0.433	0.473	0.394
2	Gradient Boosting	0.727	0.493	0.403	0.389
3	LinearSVC (L1)	0.683	0.427	0.487	0.402

YAĞMUR DEVECİ

Performans Metrikleri

Model performansını kapsamlı şekilde değerlendirmek için birden fazla metrik kullanılmıştır. Bu çalışmada sınıflandırma problemleri için Accuracy (Doğruluk), F1 Macro, Precision Macro ve Recall Macro ölçütleri tercih edilmiştir. Veri setindeki dengesizlik (imbalance) göz önünde bulundurularak, model başarısı sadece doğruluk oranıyla değil, her sınıfın (özellikle azınlık sınıfların) ne kadar doğru tahmin edildiğini gösteren F1 ve Recall skorlarıyla da analiz edilmiştir.

Doğrulama ve Ayırıştırma Stratejisi

Doğrulama süreci, veri setinin eğitim (%80) ve test (%20) olarak bölünmesiyle başlatılmıştır. Temel modellerde kullanılan %6.25'lik validasyon seti yaklaşımı, ileri seviye modellerde (XGBoost ve LightGBM) yerini daha sağlam bir yöntem olan k-fold Cross Validation (k-katlı Çapraz Doğrulama) tekniğine bırakmıştır. GridSearchCV entegrasyonu ile eğitim verisi 3 farklı parçaya bölünerek modellerin her parça üzerinde test edilmesi sağlanmış, böylece aşırı öğrenme (overfitting) riski minimize edilmiştir. Ayrıca, Pipeline mimarisi sayesinde özellik seçimi ve ölçekleme işlemleri her katlamada (fold) ayrı ayrı uygulanarak veri sızıntısı (data leakage) tamamen engellenmiştir.

Hata Analizi

Sınıflandırma modellerinin hatalarını görselleştirmek ve analiz etmek için Confusion Matrix (Karışıklık Matrisi) kullanılmıştır. Bu matrisler sayesinde modellerin hangi kaza türlerinde (örneğin "Yaralanmasız" vs "Ölümcül") hatalı tahminler yaptığı, hangi sınıflarda ise yüksek başarı gösterdiği detaylıca incelenmiştir. Özellikle sınıf dengesizliğinin model kararları üzerindeki etkisi bu matrisler üzerinden yorumlanmıştır.

Test Sonuçları ve Model Karşılaştırması

İlk aşama test sonuçlarına göre, temel modeller arasından Random Forest modeli %70.26 ile en yüksek genel doğruluğu sağlamıştı. Ancak, ciddi ve ölümlü kazaları tespit etme (Recall) yeteneğinde PCA uygulanan Logistic Regression (%49) belirli bir başarı göstermişti.

Çalışmanın ileri aşamasında projeye dahil edilen Gradient Boosting tabanlı modeller (XGBoost ve LightGBM) ve uygulanan hiperparametre optimizasyonu sonucunda genel başarı %73 seviyesine yükseltilmiştir. XGBoost, hem genel doğruluk hem de F1 skoru bakımından Random Forest modelini geride bırakarak projenin en başarılı modeli olarak belirlenmiştir. Bu sonuç, karmaşık ve dengesiz veri setlerinde gradient boosting algoritmalarının, geleneksel yöntemlere kıyasla daha üstün bir genelleme yeteneğine sahip olduğunu kanıtlamaktadır.

	Model	Accuracy	F1 Score	Precision
3	LightGBM	0.726420	0.704404	0.732792
2	XGBoost	0.726203	0.702609	0.733375
0	Logistic Regression	0.723253	0.698577	0.714642
1	Random Forest	0.693118	0.682441	0.681698

	Stage	Model	Accuracy	F1 Macro	Recall Macro	Precision Macro
0	Base	LogisticRegression	0.596246	0.375759	0.477801	0.413055
1	Base	RandomForest	0.702635	0.383303	0.389224	0.425832
2	Feature Selection	LogisticRegression	0.596096	0.375555	0.477476	0.412863
3	Feature Selection	RandomForest	0.700968	0.384080	0.389208	0.418632
4	PCA	LogisticRegression	0.601663	0.379561	0.490433	0.414365
5	PCA	RandomForest	0.692901	0.379338	0.382374	0.428588

9.RİSKLER VE AZALTMA YÖNTEMLERİ

Kübra Beyza Aybar

Bu projede veri tarafında eksik değerler, dengesiz sınıf yapısı ve yüksek boyutlu özellik uzayı gibi riskler; modelleme tarafında ise overfitting, hesaplama maliyeti ve yorumlanabilirlik ile ilişkili riskler tespit edilmiştir. Bu riskleri azaltmak amacıyla veri temizleme adımları uygulanmış, sınıf dengesizliği için class weight kullanılmış, yüksek boyutlu veri yapısı feature selection ve boyut indirgeme yöntemleri ile ele alınmıştır. Ayrıca, daha küçük ve kontrollü modeller tercih edilerek aşırı öğrenme riski sınırlandırılmıştır.

Gelecek çalışmalarda veri setinin genişletilmesi, SMOTE ve ADASYN gibi ileri seviye dengesizlik giderme yöntemlerinin denenmesi, Random Forest, XGBoost ve LightGBM gibi ensemble modellerin farklı yapılandırmalarla test edilmesi, zaman bazlı doğrulama stratejilerinin uygulanması ve model kararlarının açıklanabilirliğini artırmak amacıyla SHAP ve LIME gibi yöntemlerle daha ayrıntılı analizler yapılması planlanabilir.

Şule Kartal

Bu projede, hem veri kaynaklı hem de yöntemsel çeşitli riskler tespit edilmiş ve bu riskleri azaltmaya yönelik önlemler sistematik biçimde uygulanmıştır. Veri tarafında öne çıkan başlıca riskler; yüksek kategorik çeşitlilik nedeniyle ortaya çıkan yüksek boyutlu ve seyrek (sparse) veri yapısı, bazı değişkenlerde gözlenen yüksek eksik değer oranları, sensör veya raporlama kaynaklı olası veri kalitesi sorunları ve hedef değişkende görülen sınıf dengesizliği olarak belirlenmiştir.

Bu riskleri azaltmak amacıyla veri seti, öncelikle mantıksal tutarlılık kontrollerinden geçirilmiş ve analiz sürecini olumsuz etkileyebilecek tutarsız gözlemler değerlendirilmiştir. Eksik değerler, sayısal değişkenlerde medyan, kategorik değişkenlerde ise en sık görülen kategori kullanılarak doldurulmuştur. Ayrıca veri sızıntısını (data leakage) önlemek amacıyla, yaralanma şiddeti ile doğrudan ilişkili olduğu değerlendirilen bazı değişkenler veri setinden çıkarılmış; böylece modelin yapay olarak şişirilmiş performans üretmesinin önüne geçilmiştir.

Yöntemsel açıdan karşılaşılan başlıca riskler arasında overfitting, karmaşık modellerde ortaya çıkabilecek yorumlanabilirlik zorlukları, hesaplama maliyeti ve one-hot encoding sonrası oluşan yüksek boyutluluk yer almaktadır. Bu riskleri azaltmak için modelleme sürecine öncelikle daha basit ve kontrollü modellerle başlanmış; ardından SelectKBest (Mutual Information) ve Truncated SVD gibi özellik seçimi ve boyut indirgeme yöntemleri kullanılarak modelin gereksiz karmaşıklığı azaltılmıştır.

Sınıf dengesizliğinin model performansı üzerindeki etkisini azaltmak amacıyla, Logistic Regression modelinde **class_weight="balanced"** parametresi kullanılmıştır. Tüm veri ön işleme, dönüşüm ve modelleme adımları pipeline yapısı içerisinde uygulanarak eğitim, doğrulama ve test aşamalarında veri sızıntısı riski engellenmiştir. Ayrıca veri bölme işlemleri stratified şekilde gerçekleştirilerek her alt kümede sınıf dağılımlarının korunması sağlanmıştır.

Bu önlemler sayesinde, hem basit hem de karmaşık modeller için daha dengeli, genellenebilir ve güvenilir sonuçlar elde edilmesi amaçlanmış; modelleme sürecinde karşılaşılabilecek veri ve yöntem kaynaklı riskler büyük ölçüde kontrol altına alınmıştır.

Emine Esra Çetin

Bu çalışmada kullanılan trafik kazası veri seti, eksik değerler, hatalı girişler ve sınıflar arası dengesizlik gibi veri kaynaklı riskler içermektedir. Özellikle hız sınırı değişkenindeki gerçekçi olmayan değerler ve hedef değişkenin dengesiz dağılımı model performansını olumsuz etkileyebilecek unsurlar olarak değerlendirilmiştir. Bu riskler, veri temizleme adımlarıyla anomali değerlerin çıkarılması, eksik değerlerin uygun yöntemlerle doldurulması ve sınıf ağırlıklandırma (class_weight) yaklaşımı kullanılarak azaltılmıştır.

Yöntemsel açıdan, yüksek boyutlu One-Hot Encoding çıktıları ve ağaç tabanlı modeller aşırı öğrenme ve çalışma süresi riskleri taşımaktadır. Bu riskler, özellik seçimi (SelectKBest) ve boyut indirgeme (TruncatedSVD) uygulanarak, ayrıca histogram tabanlı optimize edilmiş algoritmalar tercih edilerek kontrol altına alınmıştır. Bunun yanında, gelişmiş modellerin yorumlanabilirliğinin sınırlı olması riski, daha basit ve yorumlanabilir doğrusal modellerle karşılaştırma yapılarak dengelenmiştir. Tüm ön işleme adımlarının Pipeline yapısı içerisinde tanımlanmasıyla veri sızıntısı ve olası dağılım kaymaları minimize edilmiştir.

Dilara Kurtul

Bu çalışmada, trafik kazası verilerinin karmaşıklığı ve modelleme sürecinin doğasından kaynaklanan riskler titizlikle analiz edilmiş ve her bir risk için somut azaltma yöntemleri uygulanmıştır.

1. Veri Kalitesi ve Tutarlılık Riskleri

- **Risk:** Veri setindeki eksik değerler ve mantıksal hatalar (örneğin hatalı girilen hız limitleri), modelin yanlış çıkarımlar yapmasına neden olabilir.
- **Azaltma Yöntemi:** SimpleImputer kullanılarak sayısal veriler için medyan, kategorik veriler için en sık tekrar eden (mode) değer ataması yapılmıştır. Ayrıca, POSTED_SPEED_LIMIT gibi kritik değişkenlerde gerçek dışı değerler filtrelenerek veri bütünlüğü korunmuştur.

2. Veri Sızıntısı (Data Leakage) Riski

- **Risk:** Kaza sonrası oluşan yaralanma istatistiklerinin (INJURIES_TOTAL vb.) modelde girdi olarak kullanılması, modelin gerçek hayatta sahip olamayacağı bilgilere dayanarak yapay bir başarı sergilemesine (leakage) yol açar.
- **Azaltma Yöntemi:** Yaralanma ile ilgili tüm yan değişkenler ve kaza raporu ID'leri eğitim başlamadan önce veri setinden çıkarılmıştır. Böylece modelin sadece kaza anındaki dışsal faktörlere (yol durumu, hava durumu, araç tipi vb.) odaklanması sağlanmıştır.

3. Sınıf Dengesizliği (Class Imbalance) Riski

- **Risk:** "Ölümcül" veya "Ağır Yaralanmalı" kaza sayısının, "Yaralanmasız" kazalara göre çok düşük olması, modelin nadir görülen ancak kritik olan sınıfları görmezden gelmesine (majority bias) neden olabilir.
- **Azaltma Yöntemi:** Linear SVC modelinde class_weight='balanced' parametresi aktive edilerek azınlık sınıfların hata maliyeti artırılmıştır. Değerlendirme aşamasında sadece "Accuracy" değerine değil, "Macro F1-Score" ve "Recall" değerlerine odaklanılarak modelin güvenliği test edilmiştir.

4. Yüksek Boyutluluk ve Aşırı Öğrenme (Overfitting) Riski

- **Risk:** One-Hot Encoding sonrası artan özellik sayısı, modelin eğitim verisini ezberlemesine ve yeni verilerde başarısız olmasına yol açabilir.
- **Azaltma Yöntemi:** Üç aşamalı bir koruma mekanizması kurulmuştur:
 - **VarianceThreshold:** Bilgi taşımayan düşük varyanslı özellikler elenmiştir.
 - **SelectKBest:** Sadece hedef değişkenle en yüksek ilişkili 50 özellik seçilmiştir.
 - **L1 Regularization:** Linear SVC modelinde L1 cezalandırması kullanılarak gereksiz katsayılar sıfırlanmış, modelin daha sade ve genellenebilir olması sağlanmıştır.

5. Doğrusal Olmayan İlişkilerin Atlanması Riski

- **Risk:** Trafik kazalarındaki değişkenler arasındaki ilişkinin doğrusal olmaması durumunda, Linear SVC gibi modellerin performansı yetersiz kalabilir.
- **Azaltma Yöntemi:** Linear SVC'ye ek olarak **Gradient Boosting** gibi doğrusal olmayan güçlü bir ensemble modeli de test edilmiştir. Bu sayede modeller arası karşılaştırma yapılarak en dengeli tahmin yapısına sahip olan model (Linear SVC L1) final yaklaşımı olarak belirlenmiştir.

6. Genelleme Hatası Riski

- **Risk:** Modelin performansının sadece eğitim setinde ölçülmesi yanıltıcı olabilir.

- **Azaltma Yöntemi:** Veri seti %75 Eğitim, %5 Doğrulama ve %20 Test olacak şekilde üç parçaya ayrılmıştır. Modelin nihai başarısı, eğitim sırasında hiç görmediği "Hold-out Test Set" üzerinde raporlanarak gerçek dünya performansı simüle edilmiştir.

YAĞMUR DEVECİ

Bu çalışmada karşılaşılabilecek temel riskler; veri kalitesi, bilgi sızıntısı (data leakage), sınıf dengesizliği, aşırı öğrenme (overfitting) ve boyut fazlalığıdır. Bu risklere karşı alınan önlemler aşağıda detaylandırılmıştır:

- **Veri Kalitesi ve Bilgi Sızıntısı (Data Leakage):** Eksik veya hatalı veriler modelin doğruluğunu düşürebileceği için, veri ön işleme aşamasında mantıksal kontroller (Sanity Checks) ve imputasyon stratejileri uygulanmıştır. Özellikle, eğitim ve test verileri arasında oluşabilecek bilgi sızıntısını (data leakage) kesin olarak engellemek amacıyla, veri işleme ve modelleme adımları Scikit-learn Pipeline mimarisi kullanılarak izole edilmiştir.
- **Sınıf Dengesizliği:** Hedef değişkendeki dengesizlik, `class_weight='balanced'` parametresi kullanımı ile minimize edilmiştir. Ayrıca, projeye eklenen XGBoost ve LightGBM gibi gelişmiş algoritmaların, dengesiz veri setlerinde hassas ayar (tuning) ile azınlık sınıflarını öğrenme kapasitesinden faydalanılmıştır.
- **Aşırı Öğrenme (Overfitting) ve Model Karmaşıklığı:** Aşırı öğrenme riski; validation set performansının izlenmesi, feature selection ve PCA gibi boyut indirgeme teknikleri ile azaltılmıştır. Buna ek olarak, modellerin ezberlemesini önlemek için GridSearchCV yöntemiyle sistematik Hiperparametre Optimizasyonu uygulanmış ve modelin kararlılığı k-katlı Çapraz Doğrulama (Cross-Validation) ile test edilerek güvence altına alınmıştır.
- **Boyut Fazlalığı:** Yüksek boyutlu verinin yarattığı hesaplama maliyeti ve gürültü, PCA yöntemi ile varyansın %95'i korunacak şekilde boyut indirgeme yapılarak kontrol altında tutulmuştur.

10.KULLANILAN ARAÇLAR

Kübra Beyza Aybar

Bu çalışmada Python ortamı kullanılmış; veri işleme ve modelleme süreçlerinde pandas, NumPy ve scikit-learn başta olmak üzere yaygın makine öğrenimi kütüphanelerinden yararlanılmıştır. Ayrıca boosting ve ensemble modeller için LightGBM, hiperparametre optimizasyonu için Optuna ve GridSearchCV kullanılmıştır. Deneylerin tekrarlanabilirliğini sağlamak amacıyla random seed değerleri sabitlenmiştir. Hesaplama yükü açısından çalışmalar CPU tabanlı olarak yürütülmüş, özel bir donanım veya GPU gereksinimi olmamıştır.

Beklenen Çalışma Süresi / Kaynaklar:

Baseline Decision Tree ve preprocessing adımlarını içeren modeller hesaplama açısından hafif olup, standart bir dizüstü bilgisayarda birkaç dakika içerisinde tamamlanabilmektedir. Feature Selection (Mutual Information) ve Truncated SVD içeren senaryolar, ek hesaplama maliyetine sahip olsa da toplam süre pratik seviyededir. LightGBM, AdaBoost, Gradient Boosting ve Stacking Ensemble gibi daha gelişmiş modellerde eğitim süresi artmakla birlikte, tüm deneyler CPU üzerinde makul sürelerde tamamlanmış ve sistem kaynakları açısından sürdürülebilir bir yapı korunmuştur.

Şule Kartal

Bu projede gerçekleştirilen tüm veri analizi, modelleme ve değerlendirme süreçleri Python 3.x tabanlı bir Jupyter Notebook ortamında yürütülmüştür. Veri işleme ve analiz aşamalarında NumPy ve Pandas, makine öğrenmesi modellerinin geliştirilmesi ve değerlendirilmesinde ise ağırlıklı olarak Scikit-Learn kütüphanesinden yararlanılmıştır. Görselleştirme süreçlerinde Matplotlib ve Seaborn kullanılarak hem keşifsel veri analizi hem de model performansına ilişkin grafikler oluşturulmuştur.

Deneylerin tekrarlanabilirliğini ve sonuçların tutarlılığını sağlamak amacıyla, rastgelelik içeren tüm adımlarda random seed değeri 42 olarak sabitlenmiştir. Bu yaklaşım sayesinde veri bölme, çapraz doğrulama ve model eğitim süreçlerinde elde edilen sonuçların yeniden üretilebilir olması garanti altına alınmıştır.

Uygulanan tüm modeller ve veri dönüşüm adımları, standart bir dizüstü bilgisayar ortamında yalnızca CPU kullanılarak çalıştırılmıştır. Çalışma kapsamında herhangi bir GPU, bulut tabanlı altyapı veya özel donanım gereksinimi bulunmamaktadır. Bu durum, geliştirilen çözümün düşük donanım gereksinimleriyle geniş kullanıcı kitlesi tarafından uygulanabilir olduğunu göstermektedir.

Veri temizleme, özellik mühendisliği, özellik seçimi, boyut indirgeme, model eğitimi ve performans değerlendirme adımlarının tamamı tek bir Jupyter Notebook dosyası içerisinde, mantıksal ve modüler bir yapı izlenerek düzenlenmiştir. Ayrıca veri sızıntısını önlemek ve süreç bütünlüğünü sağlamak amacıyla, dönüşüm ve modelleme adımları pipeline yapısı içerisinde kurgulanmıştır.

Veri setinin boyutu görece büyük olmasına rağmen, uygulanan özellik seçimi (SelectKBest – Mutual Information) ve boyut indirgeme (Truncated SVD) teknikleri sayesinde hesaplama maliyeti kontrol altında tutulmuş; preprocessing ve modelleme adımları makul süreler içerisinde tamamlanmıştır. Bu optimizasyonlar, özellikle karmaşık modellerin CPU ortamında dahi verimli şekilde eğitilmesine katkı sağlamıştır.

Proje kapsamında geliştirilen tüm kodların GitHub üzerinde versiyonlanması planlanmakta olup, bu sayede çalışmanın şeffaf, yeniden üretilebilir ve geliştirilmeye açık bir yapıda paylaşılması hedeflenmektedir. Genel olarak proje, temel donanım koşullarında sorunsuz şekilde çalışabilen, hafif ancak kapsamlı bir makine öğrenmesi çalışma ortamı sunmaktadır.

Emine Esra Çetin

Bu çalışmada Python programlama dili kullanılmış olup, geliştirme süreci Anaconda tabanlı bir Python 3.x ortamında gerçekleştirilmiştir. Veri işleme ve modelleme aşamalarında başlıca **NumPy**, **Pandas**, **Scikit-learn** ve **Matplotlib/Seaborn** kütüphanelerinden yararlanılmıştır. Deneylerin tekrarlanabilirliğini sağlamak amacıyla veri bölme ve bazı modellerde **random_state** parametresi sabitlenmiştir. Çalışma, ek bir donanım gereksinimi olmadan, standart CPU üzerinde yürütülmüş olup GPU veya yüksek bellek ihtiyacı bulunmamaktadır. Geliştirilen kodlar yerel ortamda çalıştırılmış, bu çalışma kapsamında herkese açık bir GitHub deposu paylaşılmamıştır. Kullanılan modeller ve veri boyutu göz önüne alındığında, tüm deneyler makul süreler içerisinde tamamlanmış ve önemli bir hesaplama kısıtıyla karşılaşılmamıştır.

Dilara Kurtul

Bu çalışmanın veri ön işleme, analiz, görselleştirme ve makine öğrenmesi aşamalarında, veri bilimi ekosisteminde standart kabul edilen açık kaynaklı kütüphaneler ve araçlar kullanılmıştır.

1. Programlama Dili ve Geliştirme Ortamı

- **Python 3:** Projenin tüm algoritma ve veri işleme mantığı Python dili ile kurgulanmıştır.
- **Jupyter Notebook (.ipynb):** Kodların hücre bazlı çalıştırılması, sonuçların anlık gözlemlenmesi ve analizlerin dökümanite edilmesi amacıyla kullanılmıştır.

2. Veri Manipülasyonu ve Analizi

- **Pandas:** `Traffic_Crashes.csv` veri setinin yüklenmesi, eksik verilerin analizi, sütun bazlı filtreleme ve veri temizleme işlemleri için temel araç olarak kullanılmıştır.
- **NumPy:** Matris operasyonları, sayısal hesaplamalar ve rastgele veri üretim süreçlerinde (RNG kontrolü için) yararlanılmıştır.

3. Veri Görselleştirme

- **Matplotlib:** Temel grafik yapıları ve figür düzenlemeleri için kullanılmıştır.
- **Seaborn:** Veri setindeki sınıfların dağılımını gösteren histogramlar, korelasyon analizleri ve model performansını özetleyen ısı haritalı (heatmap) Karmaşıklık Matrislerinin (Confusion Matrix) oluşturulmasında tercih edilmiştir.

4. Makine Öğrenmesi (Scikit-learn) Modelleme sürecinin merkezinde yer alan scikit-learn kütüphanesi kapsamında şu modüllerden faydalanılmıştır:

- **Pipeline & ColumnTransformer:** Veri ön işleme ve modelleme adımlarının birbirine entegre edilerek veri sızıntısının önlenmesi ve sürecin otomatize edilmesi sağlanmıştır.
- **Preprocessing:** `StandardScaler` (sayısal ölçeklendirme), `OneHotEncoder` (kategorik dönüştürme) ve `SimpleImputer` (eksik veri tamamlama) araçları kullanılmıştır.
- **Feature Selection (Özellik Seçimi):** `VarianceThreshold` ile düşük varyanslı özelliklerin elenmesi ve `SelectKBest (mutual_info_classif)` ile en anlamlı özelliklerin seçilmesi işlemleri gerçekleştirilmiştir.
- **Modeller:** `LinearSVC` (L1 ve L2 düzenlileştirmeli versiyonlar) ve `GradientBoostingClassifier` algoritmaları eğitilmiştir.
- **Model Evaluation:** `classification_report`, `accuracy_score`, `precision_recall_fscore_support` ve `confusion_matrix` fonksiyonları ile başarı metrikleri hesaplanmıştır.

5. Yardımcı Araçlar

- **Joblib:** Eğitilen modellerin kaydedilmesi ve daha sonra tekrar yüklenerek kullanılabilir hale getirilmesi için entegre edilmiştir.
- **Warnings:** Çalışma sırasında oluşan görsel karmaşıklıkları engellemek ve temiz bir çıktı raporu sunmak adına uyarı yönetimi yapılmıştır.

YAĞMUR DEVECİ

Bu projede Python 3.x programlama dili ve Jupyter Notebook geliştirme ortamı kullanılmıştır. Veri manipülasyonu ve sayısal işlemler için NumPy ve Pandas; temel makine öğrenmesi algoritmaları ve veri ön işleme adımları (preprocessing) için Scikit-Learn kütüphanesi temel alınmıştır. Projenin ileri aşamalarında, yüksek performanslı modelleme için Gradient Boosting tabanlı XGBoost ve LightGBM kütüphaneleri de teknoloji yığınına (tech stack) eklenmiştir. Görselleştirme ve keşifçi veri analizi (EDA) süreçlerinde Matplotlib ve Seaborn tercih edilmiştir. Veri işleme akışının standartlaştırılması ve tekrarlanabilirliğin sağlanması adına kodlar, Scikit-Learn Pipeline ve ColumnTransformer mimarisi üzerine inşa edilmiştir. Tüm işlemler standart bir dizüstü bilgisayarda CPU kullanılarak yürütülmüş; Feature Selection, PCA teknikleri ve LightGBM'in histogram tabanlı hızlı algoritması sayesinde hesaplama yükü optimize edilmiştir. Kodlar tek bir Notebook üzerinde düzenlenmiş olup, proje GitHub üzerinden versiyonlanmaya uygun hâle getirilmiştir. Bu sayede deneylerin tutarlılığı sağlanmış ve çalışma süresi makul seviyede tutulmuştur.

11. BEKLENEN SONUÇLAR VE GÖRSELLEŞTİRME

Kübra Beyza Aybar

Bu çalışmada geliştirilen farklı modelleme yaklaşımlarının değerlendirilmesi sonucunda, test veri kümesi üzerinde elde edilen performans metriklerinin karşılaştırmalı olarak sunulması amaçlanmıştır. Bu kapsamda her model için Accuracy, F1 Macro, Recall Macro ve Precision Macro değerleri hesaplanmış ve elde edilen sonuçlar karşılaştırma tabloları hâlinde raporlanmıştır. Böylece baseline Decision Tree modeli ile feature selection, boyut indirgeme ve boosting/ensemble tabanlı modeller arasındaki performans farkları sayısal olarak ortaya konmuştur.

Buna ek olarak, her model için oluşturulan karışıklık matrisleri (confusion matrix) kullanılarak sınıflar arası doğru ve yanlış tahminler görsel olarak analiz edilmiştir. Bu görselleştirmeler sayesinde, özellikle dengesiz sınıf yapısında hangi sınıfların daha sık karıştırıldığı ve model hatalarının hangi sınıflarda yoğunlaştığı açık biçimde incelenmiştir. Ensemble ve boosting tabanlı modellerin, sınıflar arası hataları daha dengeli dağıttığı gözlemlenmiştir.

Yorumlanabilirlik açısından, çalışmada öncelikle Decision Tree gibi yorumlanabilirliği yüksek modeller referans alınmış ve daha karmaşık LightGBM, AdaBoost, Gradient Boosting ve Stacking Ensemble modelleri ile karşılaştırmalı değerlendirme yapılmıştır. Ayrıca özellik seçimi ve boyut indirgeme adımlarının model performansı üzerindeki etkisi, metrik tabloları ve karışıklık matrisleri üzerinden dolaylı olarak yorumlanmıştır.

Şule Kartal

Bu projede, geliştirilen modellerin performansını somut, karşılaştırılabilir ve yorumlanabilir biçimde sunabilmek amacıyla çeşitli tablo ve grafik çıktıları üretilmiştir. İlk olarak, her model için doğruluk (accuracy), precision, recall ve özellikle macro F1 skoru değerlerini içeren kapsamlı bir performans karşılaştırma tablosu oluşturulmuştur. Bu tablo sayesinde doğrusal, ağaç tabanlı, derin öğrenme ve boosting tabanlı modellerin performansları tek bir çerçevede karşılaştırılabilmiştir.

Sınıflar arasındaki yanlış sınıflandırma örüntülerini ayrıntılı olarak incelemek amacıyla, her model için karışıklık matrisi (confusion matrix) görselleştirmeleri oluşturulmuştur. Bu grafikler, özellikle hangi sınıfların birbiriyle daha sık karıştırıldığını ve azınlık sınıflardaki hata davranışlarını ortaya koymak için kullanılmıştır.

Model performansını daha derinlemesine değerlendirmek amacıyla, çok sınıflı yapı uygun yöntemlerle ele alınarak ROC eğrileri ve Precision–Recall (PR) eğrileri çizilmiştir. Bu görselleştirmeler, özellikle sınıf dengesizliğinin model performansı üzerindeki etkisini incelemek ve farklı modellerin eşik duyarlılıklarını karşılaştırmak açısından önemli bilgiler sunmuştur.

Çapraz doğrulama (cross-validation) sonuçlarının model kararlılığı açısından değerlendirilmesi amacıyla, katlar (foldlar) boyunca elde edilen performans skorları görselleştirilmiş; böylece modellerin farklı veri bölünmelerine karşı gösterdiği performans dalgalanmaları analiz edilmiştir. Bu analizler, modellerin yalnızca tek bir test bölgesine değil, genel veri dağılımına karşı ne kadar tutarlı davrandığını ortaya koymuştur.

Model çıktılarının güvenilirliğini değerlendirmek amacıyla, olasılık tahmini üreten modeller için kalibrasyon eğrileri (calibration curves) incelenmiştir. Bu grafikler, modelin tahmin ettiği olasılıkların gerçek gözlemlerle ne derece uyumlu olduğunu değerlendirmeye yardımcı olmuş ve özellikle karmaşık modellerin aşırı güvenli veya aşırı temkinli tahmin davranışlarını analiz etme imkânı sağlamıştır.

Modelin karar mekanizmasını daha iyi açıklayabilmek amacıyla, özellik önem grafikleri ve Mutual Information (MI) tabanlı özellik seçimi sonuçları görselleştirilmiştir. Gerekli görülen durumlarda, model tahminlerine etki eden değişkenlerin daha ayrıntılı biçimde analiz edilebilmesi için SHAP tabanlı açıklanabilirlik yöntemleri kullanılarak hangi özelliklerin tahmine en fazla katkı sağladığı ortaya konmuştur.

Ek olarak, modelin belirli sınıflarda neden hata yaptığına dair içgörü elde edebilmek amacıyla hata dökümleri ve örnek bazlı analizler gerçekleştirilmiştir. Bu analizler sayesinde yanlış sınıflandırmaların veri kaynaklı mı yoksa model yapısından mı kaynaklandığı değerlendirilmiş; elde edilen bulgular sonuçların yorumlanmasında kullanılmıştır.

Tüm bu tablo ve görselleştirme çıktıları, projenin yalnızca performans odaklı değil, aynı zamanda yorumlanabilirlik ve model güvenilirliği boyutlarını da kapsayan bütüncül bir değerlendirme sunmasını hedeflemektedir.

Emine Esra Çetin

Bu çalışmada geliştirilen modellerin değerlendirilmesi sonucunda, test veri kümesi üzerinde elde edilen performans metriklerinin karşılaştırmalı olarak sunulması beklenmektedir. Bu kapsamda her model için accuracy, precision, recall ve F1-score değerleri hesaplanmış ve bu değerler bir karşılaştırma tablosu hâlinde raporlanmıştır. Böylece temel doğrusal modeller ile gelişmiş ağaç tabanlı modellerin performans farkları sayısal olarak ortaya konmuştur. Bunun yanında, her model için oluşturulan karışıklık matrisleri (confusion matrix) kullanılarak sınıflar arası doğru ve yanlış tahminler görsel olarak analiz edilmiştir. Bu görselleştirmeler, özellikle hangi yaralanma şiddeti sınıflarının daha sık karıştırıldığını ve model hatalarının hangi sınıflarda yoğunlaştığını incelemek amacıyla kullanılmıştır.

Yorumlanabilirlik açısından, çalışmada doğrudan özellik önemi veya SHAP/LIME gibi ileri açıklanabilirlik yöntemleri kullanılmamış; bunun yerine, yorumlanabilirliği yüksek olan lojistik regresyon modeli referans alınarak daha karmaşık modellerle karşılaştırma yapılmıştır. Ayrıca özellik seçimi ve boyut indirgeme adımlarının model performansı üzerindeki etkisi, metrik tabloları üzerinden

dolaylı olarak yorumlanmıştır. Sunulan tablolar ve karışıklık matrisleri, en başarılı modelin belirlenmesi ve model davranışının genel hatlarıyla anlaşılması için yeterli bir görselleştirme ve analiz altyapısı sağlamaktadır.

Dilara Kurtul

Proje kapsamında gerçekleştirilen analizler ve modelleme çalışmaları sonucunda elde edilen veriler, hem teorik beklentileri hem de veri setine özgü pratik sonuçları ortaya koymuştur.

1. Performans Beklentileri ve Gerçekleşen Sonuçlar

- **Doğruluk ve Esneklik:** Başlangıçta ensemble modellerin (Gradient Boosting vb.) karmaşık veri yapısı nedeniyle Linear SVC'ye kıyasla çok daha yüksek başarı sergileyeceği öngörülmüştür. Gerçekten de Gradient Boosting, genel doğruluk (accuracy) skorunda en yüksek seviyeye ulaşmıştır.
- **Sınıf Bazlı Hassasiyet:** Azınlık sınıfların (Fatal, Incapacitating Injury) tahmini konusunda, doğrusal modellerin (Linear SVC) düzenleme ve ağırlıklandırma teknikleri sayesinde ensemble modellere göre daha dengeli ve "macro" metriklerde daha tutarlı sonuçlar üretebildiği saptanmıştır. Bu durum, projenin en önemli çıktılarından biridir.

2. Görselleştirme Stratejisi Sonuçların hem teknik hem de yönetsel açıdan anlaşılır kılınması için şu görselleştirme araçlarından yararlanılmıştır:

- **Karışıklık Matrisi (Confusion Matrix):** Her bir modelin hangi yaralanma şiddetini diğeriyle karıştırdığını net bir şekilde görmek için kullanılmıştır. Özellikle "Fatal" kazaların "No Injury" olarak tahmin edilme oranı bu grafikler üzerinden analiz edilmiştir.
- **Performans Karşılaştırma Grafikleri:** Modellerin Accuracy, Precision, Recall ve F1-Score değerlerini yan yana getiren sütun grafikleri oluşturulmuştur. Bu, modellerin birbirine karşı üstünlük kurduğu noktaları somutlaştırmıştır.
- **Özellik Önem Dereceleri (Feature Importance):** Gradient Boosting modeli üzerinden, kaza şiddetini en çok etkileyen faktörler (örneğin; hava durumu, hız limiti, kaza tipi) görselleştirilmiştir. Bu sayede hangi değişkenlerin tahminleme sürecinde "ayırt edici" olduğu raporlanmıştır.

3. Projenin Sağlayacağı Katkılar Görsel ve sayısal sonuçların birleşimiyle proje sonunda şu çıktılar hedeflenmiştir:

- Chicago trafik kazaları verisi üzerinde yüksek genelleme başarısına sahip bir tahminleme yapısı.
- Sınıf dengesizliği içeren kamu verilerinde hangi modelleme stratejisinin (doğrusal vs. ensemble) daha "güvenli" olduğunun ispatı.
- Trafik güvenliği ekipleri için kaza anında hızlı şiddet tahmini yapabilen bir karar destek mekanizması referansı.

YAĞMUR DEVECİ

Bu çalışmanın sonucunda, veri hazırlama ve modelleme adımlarının performans üzerindeki etkisi karşılaştırmalı ve kanıta dayalı olarak ortaya konulmuştur. Başlangıçta kurulan Base modellerin üzerine Feature Selection ve PCA adımları eklenmiş; nihai aşamada XGBoost ve LightGBM gibi ileri seviye algoritmalar ve Hiperparametre Optimizasyonu uygulanarak Accuracy, F1 Macro ve Recall metriklerinde belirgin iyileşmeler gözlemlenmiştir.

Özellik mühendisliği ile türetilen yeni sütunlar ve kurulan Pipeline mimarisi sayesinde modelin genellebilirliği artırılmış, eğitim ve test setleri arasındaki performans farkı minimize edilerek aşırı öğrenmenin (overfitting) önüne geçilmiştir.

Görselleştirme kapsamında aşağıdaki analizler gerçekleştirilmiş ve rapora sunulmuştur:

1. **Keşifçi Veri Analizi (EDA):** Hedef değişkenin ve sayısal özelliklerin dağılımı histogram ve boxplot'lar ile incelenmiş, veri setindeki dengesizlik ve uç değerler tespit edilmiştir. Özellikler arasındaki ilişkiler korelasyon heatmap'leri ile görselleştirilmiştir.
2. **Model Performans Analizi:**
 - **Karışıklık Matrisleri (Confusion Matrix):** Modellerin sınıf bazlı hata oranları detaylandırılmış, özellikle "Ölümcül" ve "Ciddi Yaralanmalı" kaza türlerinin tahmin başarısı analiz edilmiştir.
 - **Öznitelik Önem Grafikleri (Feature Importance Plots):** En başarılı model olan XGBoost'un karar verirken hangi değişkenlere (örn. Kaza Türü, Hız Sınırı) öncelik verdiği bar grafikleri ile ortaya konulmuştur.
 - **Karşılaştırmalı Performans Tabloları:** Tüm modellerin (Logistic Regression, Random Forest, XGBoost, LightGBM) doğruluk ve F1 skorları kıyaslanarak, projenin en iyi performansı veren modeli belirlenmiştir.

Bu sonuçlar, veri odaklı yaklaşımların ve gelişmiş algoritmaların trafik kazalarındaki yaralanma şiddetini tahmin etmede etkin bir araç olduğunu kanıtlamaktadır.

12.SONUÇLAR

Kübra Beyza Aybar

Bu çalışmada, ön işleme, özellik seçimi ve boyut indirgeme adımları ile desteklenen farklı makine öğrenimi modelleri karşılaştırmalı olarak değerlendirilmiştir. Baseline Decision Tree modeli referans alınarak; Mutual Information tabanlı Feature Selection, Truncated SVD, boosting ve ensemble tabanlı yaklaşımların model performansına etkisi analiz edilmiştir. Değerlendirmeler, sınıf dengesizliğini dikkate alan F1 Macro, Recall Macro ve Precision Macro metrikleri üzerinden gerçekleştirilmiştir.

Elde edilen sonuçlar, Accuracy açısından baseline modelin güçlü bir performans sunduğunu, ancak Feature Selection uygulanan senaryonun daha dengeli ve genellenebilir sonuçlar ürettiğini göstermiştir. Truncated SVD kullanılan senaryoda ise boyut indirgeme sırasında oluşan bilgi kaybı nedeniyle performans düşüşü gözlemlenmiştir. LightGBM, AdaBoost, Gradient Boosting ve Stacking Ensemble gibi gelişmiş modeller, özellikle F1 Macro metriği açısından daha kararlı ve dengeli sonuçlar sunarak sınıf dengesizliği problemini daha etkin biçimde yönetmiştir.

Genel olarak çalışma, uygun özellik seçimi ve ensemble tabanlı yöntemlerin, yalnızca doğruluk odaklı yaklaşımlara kıyasla daha güvenilir ve dengeli bir modelleme süreci sunduğunu ortaya koymuştur. Elde edilen bulgular, gerçek dünya verileriyle çalışılan çok sınıflı ve dengesiz problemler için model seçiminde F1 Macro gibi bütüncül metriklerin önemini açıkça göstermektedir.

Emine Esra Çetin

Çalışma sürecinde öncelikle veri temizleme ve veri hazırlama adımları gerçekleştirilmiş; eksik değerler uygun yöntemlerle doldurulmuş, gerçekçi olmayan gözlemler veri setinden çıkarılmış ve veri sızıntısı riski taşıyan değişkenler modelleme sürecine dahil edilmemiştir. Ardından, sayısal ve kategorik değişkenler için ayrı ön işleme adımları uygulanmış, One-Hot Encoding sonrası oluşan yüksek boyutlu yapı özellik seçimi ve boyut indirgeme yöntemleriyle kontrol altına alınmıştır. Tüm bu adımlar, veri sızıntısını önlemek ve deneysel tutarlılığı sağlamak amacıyla Pipeline yapısı içerisinde gerçekleştirilmiştir.

Modelleme aşamasında hem temel doğrusal modeller hem de gelişmiş ağaç tabanlı sınıflandırma algoritmaları kullanılarak farklı öğrenme yaklaşımlarının performansları karşılaştırılmıştır. Passive-Aggressive Classifier ve dengelenmiş Lojistik Regresyon modelleri temel karşılaştırma noktaları olarak ele alınırken, HistGradientBoostingClassifier ve ExtraTreesClassifier modelleri daha karmaşık ilişkileri yakalayabilen gelişmiş yöntemler olarak değerlendirilmiştir. Sınıf dengesizliği problemi göz önünde bulundurularak, performans değerlendirmesi accuracy metriğinin yanı sıra weighted precision, recall ve F1-score gibi metrikler üzerinden yapılmış, ayrıca her model için karışıklık matrisleri incelenerek hata örüntüleri analiz edilmiştir.

Elde edilen sonuçlar, ağaç tabanlı ve boosting temelli modellerin doğrusal modellere kıyasla daha dengeli ve yüksek performans sunduğunu göstermiştir. Özellikle HistGradientBoostingClassifier modeli, test veri kümesi üzerinde en yüksek accuracy ve F1-score değerlerine ulaşarak çalışmadaki en başarılı model olmuştur. Bu bulgular, trafik kazası verisi gibi karmaşık ve dengesiz yapıya sahip veri setlerinde, doğrusal olmayan ilişkileri öğrenebilen gelişmiş modellerin daha etkili sonuçlar üretebildiğini ortaya koymaktadır. Çalışma boyunca izlenen sistematik veri hazırlama, modelleme ve değerlendirme süreci, elde edilen sonuçların güvenilir ve tekrarlanabilir olmasını sağlamıştır.

YAĞMUR DEVECİ

Bu çalışmada, Chicago trafik kazaları veri seti üzerinde yaralanma şiddetinin tahmini için geliştirilen makine öğrenmesi modellerinin performans analizleri gerçekleştirilmiştir. Yapılan deneyler sonucunda, temel (baseline) modeller ile ileri seviye gradient boosting algoritmaları arasında belirgin performans farkları tespit edilmiştir. Başlangıçta kullanılan Lojistik Regresyon modeli %60.19 doğruluk ve 0.64 F1 skoru elde ederken, Random Forest algoritması %70.24 doğruluk ve 0.69 F1 skoru ile daha yüksek bir başarıyı sergilemiştir. Projenin optimizasyon aşamasında devreye alınan ve GridSearchCV ile hiperparametre ayarları yapılan XGBoost modeli ise %73.00 doğruluk oranı ve 0.70 ağırlıklı F1 skoru (Weighted F1-Score) ile tüm modeller arasında en yüksek performansa ulaşmıştır. Benzer şekilde, LightGBM modeli de %73.00 doğruluk oranı ile XGBoost ile eşdeğer bir başarı göstermiştir.

Modellerin sınıf bazlı tahmin performansları incelendiğinde, veri setindeki sınıf dağılımına paralel sonuçlar elde edilmiştir. XGBoost, veri setinin çoğunluğunu oluşturan "Yaralanmasız" (No Indication of Injury) sınıfını %97 kesinlik (Precision) ve %92 F1 skoru ile tahmin etmiştir. İkinci en yoğun sınıf olan "Hafif Yaralanmalı" (Non-Incapacitating) kazalarda ise model %51 kesinlik ve %86 duyarlılık (Recall) değerlerine ulaşarak %64 F1 skoru elde etmiştir. Ancak, veri setinde sayıca az bulunan "Ciddi

Yaralanmalı" (Incapacitating) ve "Ölümcül" (Fatal) kaza sınıflarında modelin duyarlılık oranları düşük seviyede kalmış, bu sınıfların ayırt edilmesinde modelin zorlandığı görülmüştür.

Modelin karar verme sürecinde etkili olan faktörlerin belirlenmesi amacıyla yapılan öznetelik önem düzeyi (Feature Importance) analizinde, kaza şiddetini etkileyen en belirleyici değişkenin açık ara farkla "Kaza Türü" (CRASH_TYPE_INJURY) olduğu saptanmıştır. Bu değişkeni sırasıyla "Kaza Saati" (CRASH_HOUR), "Hız Sınırı" (POSTED_SPEED_LIMIT) ve "Trafik Kontrol Cihazı Varlığı" (TRAFFIC_CONTROL_DEVICE) takip etmektedir. Özellikle hız sınırının yüksek olduğu bölgelerde ve belirli saat dilimlerinde gerçekleşen kazaların, yaralanma şiddeti tahmini üzerinde istatistiksel olarak anlamlı bir etkisi olduğu model çıktılarıyla doğrulanmıştır.

Şule Kartal

Bu çalışmada, Chicago trafik kazaları veri seti kullanılarak yaralanma şiddetinin tahmin edilmesine yönelik kapsamlı bir makine öğrenmesi analizi gerçekleştirilmiştir. Çalışma sürecinde veri hazırlama, özellik mühendisliği, modelleme ve değerlendirme adımları bir bütün olarak ele alınmış; hem temel (baseline) hem de karmaşık model aileleri sistematik biçimde incelenmiştir.

Modelleme sürecinin ilk aşamasında, problem yapısını daha iyi anlayabilmek ve karşılaştırma için sağlam bir referans oluşturmak amacıyla Logistic Regression ve Linear Support Vector Classifier (Linear SVC) gibi doğrusal ve yorumlanabilir modeller kullanılmıştır. Bu modeller, düşük hesaplama maliyetleri ve sade yapıları sayesinde veri setindeki genel örüntüleri yakalamada temel bir performans seviyesi sunmuş; aynı zamanda sınıf dengesizliği ve yüksek boyutluluk gibi zorlukların model performansı üzerindeki etkilerinin gözlemlenmesine olanak sağlamıştır. Elde edilen sonuçlar, base modellerin belirli bir başarı düzeyine ulaşabildiğini ancak doğrusal varsayımlar nedeniyle karmaşık ilişkileri sınırlı ölçüde temsil edebildiğini göstermiştir.

Bu temel modellerin ardından, doğrusal olmayan ilişkileri ve değişkenler arası etkileşimleri daha iyi yakalayabilmek amacıyla Decision Tree, Random Forest ve boosting tabanlı yöntemler uygulanmıştır. Ağaç tabanlı modeller, özellikle değişkenler arası etkileşimleri öğrenme konusunda base modellere kıyasla daha esnek bir yapı sunmuş; performans metriklerinde belirgin iyileşmeler sağlamıştır. Bununla birlikte, bu modellerin uygun hiperparametre ayarlamaları ve özellik seçimi yapılmadığında aşırı öğrenmeye daha yatkın olduğu da gözlemlenmiştir.

Çalışma kapsamında ayrıca, sinir ağı tabanlı yaklaşımı temsil eden Multi-Layer Perceptron (MLP) modeli ve kategorik değişkenlerle etkin biçimde çalışabilen CatBoost modeli değerlendirilmiştir. MLP modeli, doğrusal olmayan örüntüleri öğrenme kapasitesi sayesinde bazı senaryolarda performans artışı sağlarken; CatBoost modeli, kategorik değişkenleri ele alma biçimi ve düzenleştirme mekanizmaları sayesinde sınıflar arası daha dengeli ve tutarlı sonuçlar üretmiştir. Bu modeller, özellikle macro F1 metriği açısından base modellere göre daha güçlü bir performans sergilemiştir.

Model değerlendirme sürecinde, sınıf dengesizliği göz önünde bulundurularak doğruluk metriği tek başına yeterli kabul edilmemiş; macro F1, precision, recall ve karışıklık matrisi gibi metrikler birlikte kullanılmıştır. Ayrıca özellik seçimi ve boyut indirgeme adımlarının model performansına etkisi analiz edilmiş; Mutual Information tabanlı özellik seçimi ve Truncated SVD uygulamalarının, özellikle karmaşık modellerde performans-hesaplama maliyeti dengesini iyileştirdiği görülmüştür.

Genel olarak elde edilen bulgular, base modellerin güçlü bir başlangıç ve karşılaştırma noktası sunduğunu; ancak problemdeki karmaşık ilişkilerin daha iyi modellenebilmesi için ağaç tabanlı, boosting ve sinir ağı tabanlı yöntemlerin daha yüksek ve dengeli performans sağladığını ortaya koymaktadır. Bununla birlikte, karmaşık modellerin başarısının büyük ölçüde uygun veri ön işleme, özellik seçimi ve düzenleştirme adımlarına bağlı olduğu da açıkça gözlemlenmiştir.

Sonuç olarak bu çalışma, gerçek dünya verisi üzerinde hem basit hem de karmaşık makine öğrenmesi modellerinin güçlü ve zayıf yönlerini karşılaştırmalı biçimde ortaya koymakta; doğru veri hazırlama ve değerlendirme stratejileriyle güvenilir, yorumlanabilir ve genellenebilir sonuçlar elde edilebileceğini göstermektedir. Geliştirilen yaklaşım, düşük donanım gereksinimleriyle uygulanabilir olması ve kapsamlı model karşılaştırmaları içermesi açısından hem akademik hem de pratik uygulamalar için sağlam bir temel sunmaktadır.

DİLARA KURTUL

Bu çalışmada, Chicago şehri trafik kazası verileri üzerinden kazaların şiddetini (yaralanma derecesini) özyinelemeli olarak tahmin eden kapsamlı bir makine öğrenmesi hattı (pipeline) başarıyla kurgulanmıştır. Elde edilen sonuçlar ve projeden çıkarılan temel dersler aşağıda özetlenmiştir:

- 1. Model Başarısı ve Metriklerin Yorumlanması:** Modelleme sürecinde elde edilen en yüksek genel doğruluk (accuracy) değeri Gradient Boosting modeliyle sağlanmış olsa da; bu çalışmanın en önemli teknik bulgusu, "doğruluk" metriğinin tek başına yanıltıcı olabileceğidir. Sınıf dengesizliği içeren bu veri setinde, L1 düzenlileştirmeli Linear SVC modelinin, "Fatal" (Ölümcül) ve "Incapacitating Injury" (Ağır Yaralanma) gibi kritik azınlık sınıfları yakalamada daha tutarlı bir performans sergilediği ve Macro F1-Score bazında daha güvenilir bir yapı sunduğu saptanmıştır.
- 2. Özellik Seçimi ve Veri Sadeleştirme:** `VarianceThreshold` ve `SelectKBest` (Mutual Information) yöntemleriyle gerçekleştirilen özellik seçimi süreci, modelin 50 temel özelliğe odaklanmasını sağlayarak hesaplama maliyetini düşürmüştür. L1 cezalandırması (penalty) sayesinde modelin, kaza şiddetini belirleyen en ayırt edici faktörleri (hız limiti, kaza tipi, hava durumu vb.) otomatik olarak seçebildiği ve gereksiz gürültüden arındığı doğrulanmıştır.
- 3. Teknik ve Pratik Katkılar:** Geliştirilen modelleme yapısı, sadece bir tahmin aracı değil, aynı zamanda Chicago şehri trafik güvenliği analizi için bir karar destek mekanizması niteliğindedir. Kaza anında toplanan ilk verilerle yaralanma şiddetinin yüksek doğrulukla tahmin edilebilmesi, acil müdahale ekiplerinin (ambulans, itfaiye vb.) daha hızlı ve doğru şekilde yönlendirilmesine olanak tanıma potansiyeline sahiptir.
- 4. Gelecek Çalışmalar için Öneriler:** Projenin mevcut başarısını bir adım ileriye taşımak adına; azınlık sınıfların performansını artırmak için SMOTE gibi sentetik veri üretim tekniklerinin uygulanması, derin öğrenme tabanlı MLP (Multi-Layer Perceptron) modellerinin test edilmesi ve hiperparametre optimizasyonu için daha geniş çaplı bir `GridSearchCV` sürecinin yürütülmesi önerilmektedir.

Genel Değerlendirme: Bu proje; veri temizleme, sızıntı (leakage) kontrolü, özellik mühendisliği ve karşılaştırmalı modelleme adımlarıyla, gerçek dünya verileri üzerinde uçtan uca bir veri bilimi projesinin tüm gerekliliklerini başarıyla yerine getirmiştir. Seçilen nihai model, yüksek tahmin gücü ile sınıflar arası dengeyi optimize ederek trafik güvenliği alanında uygulanabilir bir çözüm sunmaktadır.

13.TABLolar

Kullanılan Bütün Modeller

	Stage	Model	Kullanan Kiři	Accuracy	F1 weighted	Recall weighted	Precision weighted
0	Base Model	Passive-Aggressive Classifier	Emine Esra etin	0.55	0.60	0.55	0.71
1	Base Model	Balanced Logistic Regression	Emine Esra etin	0.61	0.64	0.61	0.72
2	Advanced Model	HistGradientBoostingClassifier	Emine Esra etin	0.68	0.70	0.68	0.73
3	Advanced Model	ExtraTreesClassifier	Emine Esra etin	0.66	0.69	0.66	0.73
4	Base Model	Logistic Regression	Yağmur Deveci	0.60	0.64	0.73	0.60
5	Base Model	Random Forest	Yağmur Deveci	0.70	0.69	0.69	0.70
6	Advanced Model	LightGBM	Yağmur Deveci	0.73	0.70	0.73	0.73
7	Advanced Model	XGBoost	Yağmur Deveci	0.73	0.70	0.74	0.73
8	Base Model	Logistic Regression	řule Kartal	0.61	0.64	0.51	0.74
9	Advanced Model	CatBoost	řule Kartal	0.61	0.65	0.61	0.73
10	Advanced Model	MLP	řule Kartal	0.70	0.70	0.71	0.70
11	Base Model	Decision Tree	Kübra Beyza Aybar	0.65	0.37	0.37	0.37
12	Base Model	Decision Tree(MI)	Kübra Beyza Aybar	0.63	0.38	0.40	0.38
13	Base Model	Decision Tree(SVD)	Kübra Beyza Aybar	0.63	0.36	0.36	0.36
14	Advanced Model	LightGBM	Kübra Beyza Aybar	0.65	0.41	0.45	0.41
15	Advanced Model	AdaBoost	Kübra Beyza Aybar	0.63	0.39	0.47	0.42
16	Advanced Model	Gradient Boosting	Kübra Beyza Aybar	0.72	0.38	0.40	0.48
17	Base Model	LinearSVC	Dilara Kurtul	0.68	0.42	0.48	0.40
18	Base Model	LinearSVC + FS&VT	Dilara Kurtul	0.68	0.43	0.47	0.39
19	Advanced Model	Gradient Boosting	Dilara Kurtul	0.72	0.49	0.40	0.38
20	Advanced Model	LinearSVC (L1)	Dilara Kurtul	0.68	0.42	0.48	0.40

Kübra Beyza Aybar

--- 1. SENARYO: BASE MODEL (DECISION TREE) EGITIMI ---

--- BASE MODEL SONUÇLARI ---

Accuracy: 0.6525166666666666

Weighted F1 Score: 0.6560141485926545

Sınıflandırma Raporu:

	precision	recall	f1-score	support
FATAL	0.02	0.02	0.02	212
INCAPACITATING INJURY	0.13	0.14	0.13	3281
NO INDICATION OF INJURY	0.90	0.88	0.89	31398
NONINCAPACITATING INJURY	0.50	0.50	0.50	15977
REPORTED, NOT EVIDENT	0.32	0.33	0.32	9132
accuracy			0.65	60000
macro avg	0.37	0.37	0.37	60000
weighted avg	0.66	0.65	0.66	60000

--- 2. SENARYO: FEATURE SELECTION (MI) + DECISION TREE ---

--- FEATURE SELECTION MODEL SONUÇLARI --0-
Accuracy: 0.6371
Weighted F1 Score: 0.6585648224563913

Sınıflandırma Raporu:

	precision	recall	f1-score	support
FATAL	0.02	0.08	0.03	212
INCAPACITATING INJURY	0.12	0.23	0.16	3281
NO INDICATION OF INJURY	0.95	0.87	0.91	31398
NONINCAPACITATING INJURY	0.50	0.39	0.44	15977
REPORTED, NOT EVIDENT	0.35	0.42	0.38	9132
accuracy			0.64	60000
macro avg	0.39	0.40	0.38	60000
weighted avg	0.69	0.64	0.66	60000

--- 3. SENARYO: DIMENSION REDUCTION (SVD) + DECISION TREE ---

--- DIMENSION REDUCTION MODEL SONUÇLARI ---
Accuracy: 0.6358
Weighted F1 Score: 0.6377240420234596

Sınıflandırma Raporu:

	precision	recall	f1-score	support
FATAL	0.02	0.03	0.02	212
INCAPACITATING INJURY	0.11	0.12	0.11	3281
NO INDICATION OF INJURY	0.87	0.87	0.87	31398
NONINCAPACITATING INJURY	0.49	0.48	0.48	15977
REPORTED, NOT EVIDENT	0.32	0.32	0.32	9132
accuracy			0.64	60000
macro avg	0.36	0.36	0.36	60000

--- Classification Report | LightGBM (Optuna Manual) ---

	precision	recall	f1-score	support
FATAL	0.03	0.17	0.06	212
INCAPACITATING INJURY	0.16	0.28	0.20	3281
NO INDICATION OF INJURY	0.99	0.86	0.92	31398
NONINCAPACITATING INJURY	0.53	0.38	0.44	15977
REPORTED, NOT EVIDENT	0.38	0.59	0.46	9132
accuracy			0.66	60000
macro avg	0.42	0.46	0.42	60000
weighted avg	0.73	0.66	0.68	60000

--- Classification Report | AdaBoost ---

	precision	recall	f1-score	support
FATAL	0.01	0.55	0.03	212
INCAPACITATING INJURY	0.18	0.19	0.18	3281
NO INDICATION OF INJURY	1.00	0.85	0.92	31398
NONINCAPACITATING INJURY	0.48	0.47	0.48	15977
REPORTED, NOT EVIDENT	0.45	0.31	0.37	9132
accuracy			0.63	60000
macro avg	0.42	0.47	0.40	60000
weighted avg	0.73	0.63	0.67	60000

--- Classification Report | Stacking Ensemble ---

	precision	recall	f1-score	support
FATAL	0.02	0.64	0.04	212
INCAPACITATING INJURY	0.12	0.19	0.15	3281
NO INDICATION OF INJURY	0.99	0.86	0.92	31398
NONINCAPACITATING INJURY	0.54	0.23	0.32	15977
REPORTED, NOT EVIDENT	0.39	0.59	0.47	9132
accuracy			0.61	60000
macro avg	0.41	0.50	0.38	60000
weighted avg	0.73	0.61	0.65	60000

--- Classification Report | Gradient Boosting ---

	precision	recall	f1-score	support
FATAL	0.15	0.03	0.05	212
INCAPACITATING INJURY	0.32	0.00	0.00	3281
NO INDICATION OF INJURY	0.96	0.88	0.92	31398
NONINCAPACITATING INJURY	0.51	0.86	0.64	15977
REPORTED, NOT EVIDENT	0.50	0.24	0.32	9132
accuracy			0.73	60000
macro avg	0.49	0.40	0.39	60000
weighted avg	0.73	0.73	0.70	60000

Emine Esra Çetin

--- Base Model (Passive-Aggressive) Sonuçları (Validation Set) ---
Base Model Doğruluk (Accuracy): 0.5472

Sınıflandırma Raporu:

	precision	recall	f1-score	support
FATAL	0.01	0.79	0.02	42
INCAPACITATING INJURY	0.09	0.12	0.10	656
NO INDICATION OF INJURY	0.96	0.87	0.91	6279
NONINCAPACITATING INJURY	0.52	0.21	0.30	3196
REPORTED, NOT EVIDENT	0.42	0.19	0.26	1827
accuracy			0.55	12000
macro avg	0.40	0.43	0.32	12000
weighted avg	0.71	0.55	0.60	12000

=====

MODEL 1: Feature Selection + Passive-Aggressive Classifier

=====

Accuracy: 0.5459

Sınıflandırma Raporu:

	precision	recall	f1-score	support
FATAL	0.01	0.76	0.02	42
INCAPACITATING INJURY	0.07	0.07	0.07	656
NO INDICATION OF INJURY	0.92	0.87	0.89	6279
NONINCAPACITATING INJURY	0.58	0.06	0.11	3196
REPORTED, NOT EVIDENT	0.37	0.45	0.40	1827
accuracy			0.55	12000
macro avg	0.39	0.44	0.30	12000
weighted avg	0.70	0.55	0.56	12000

=====

MODEL 1: Dim. Reduction (SVD=50) + SGD Classifier

=====

Model eğitiliyor (Boyut İndirgeme ile)...

Accuracy: 0.6822

Sınıflandırma Raporu:

	precision	recall	f1-score	support
FATAL	0.02	0.38	0.04	42
INCAPACITATING INJURY	0.21	0.04	0.07	656
NO INDICATION OF INJURY	0.99	0.87	0.93	6279
NONINCAPACITATING INJURY	0.52	0.56	0.54	3196
REPORTED, NOT EVIDENT	0.40	0.49	0.44	1827
accuracy			0.68	12000
macro avg	0.43	0.47	0.41	12000
weighted avg	0.73	0.68	0.70	12000

--- HistGradientBoosting Sonuçları (Validation) ---
Accuracy: 0.6245

Sınıflandırma Raporu:

	precision	recall	f1-score	support
FATAL	0.03	0.71	0.05	42
INCAPACITATING INJURY	0.16	0.28	0.20	656
NO INDICATION OF INJURY	1.00	0.86	0.92	6279
NONINCAPACITATING INJURY	0.54	0.23	0.33	3196
REPORTED, NOT EVIDENT	0.38	0.61	0.47	1827
accuracy			0.62	12000
macro avg	0.42	0.54	0.39	12000
weighted avg	0.73	0.62	0.65	12000

--- Balanced Logistic Regression Sonuçları (Validation Set) ---
Model Doğruluk (Accuracy): 0.6123

Sınıflandırma Raporu:

	precision	recall	f1-score	support
FATAL	0.02	0.71	0.04	42
INCAPACITATING INJURY	0.15	0.25	0.19	656
NO INDICATION OF INJURY	1.00	0.86	0.93	6279
NONINCAPACITATING INJURY	0.52	0.20	0.29	3196
REPORTED, NOT EVIDENT	0.37	0.60	0.46	1827
accuracy			0.61	12000
macro avg	0.41	0.53	0.38	12000
weighted avg	0.72	0.61	0.64	12000

=====

MODEL 2: Feature Selection + Balanced Logistic Regression

=====

Accuracy: 0.6123

Sınıflandırma Raporu:

	precision	recall	f1-score	support
FATAL	0.02	0.69	0.04	42
INCAPACITATING INJURY	0.15	0.25	0.19	656
NO INDICATION OF INJURY	1.00	0.86	0.93	6279
NONINCAPACITATING INJURY	0.52	0.20	0.29	3196
REPORTED, NOT EVIDENT	0.38	0.60	0.46	1827
accuracy			0.61	12000
macro avg	0.41	0.52	0.38	12000
weighted avg	0.73	0.61	0.64	12000

=====

MODEL 2: Dim. Reduction (SVD=50) + Balanced Logistic Regression

=====

Model eğitiliyor (Boyut İndirgeme ile)...

Accuracy: 0.6070

Sınıflandırma Raporu:

	precision	recall	f1-score	support
FATAL	0.02	0.76	0.04	42
INCAPACITATING INJURY	0.15	0.25	0.19	656
NO INDICATION OF INJURY	1.00	0.86	0.92	6279
NONINCAPACITATING INJURY	0.53	0.19	0.27	3196
REPORTED, NOT EVIDENT	0.38	0.60	0.46	1827
accuracy			0.61	12000
macro avg	0.41	0.53	0.38	12000
weighted avg	0.73	0.61	0.64	12000

--- ExtraTrees Sonuçları (Validation) ---
Accuracy: 0.6647

Sınıflandırma Raporu:

	precision	recall	f1-score	support
FATAL	0.02	0.14	0.04	42
INCAPACITATING INJURY	0.15	0.26	0.19	656
NO INDICATION OF INJURY	0.99	0.87	0.93	6279
NONINCAPACITATING INJURY	0.52	0.45	0.48	3196
REPORTED, NOT EVIDENT	0.39	0.50	0.44	1827
accuracy			0.66	12000
macro avg	0.42	0.44	0.42	12000
weighted avg	0.73	0.66	0.69	12000

```

--- ExtraTrees (FS) TEST Set Sonuçları ---
Test Accuracy: 0.6617

Sınıflandırma Raporu:
                                precision    recall  f1-score   support

      FATAL                     0.02         0.17         0.04         212
    INCAPACITATING INJURY       0.14         0.23         0.18         3282
    NO INDICATION OF INJURY      0.99         0.86         0.92        31395
    NONINCAPACITATING INJURY     0.52         0.46         0.49        15977
    REPORTED, NOT EVIDENT        0.39         0.51         0.44         9131

    accuracy                     0.66        59997
    macro avg                    0.41         0.44         0.41        59997
    weighted avg                  0.73         0.66         0.69        59997

Model Val_Accuracy
1      ExtraTrees (FS)          0.664667
0 HistGradientBoosting (FS)    0.624500

```

```

=== TUNED ExtraTrees (FS) - VALIDATION ===
Validation Accuracy: 0.6647
                                precision    recall  f1-score   support

      FATAL                     0.02         0.14         0.04          42
    INCAPACITATING INJURY       0.15         0.26         0.19         656
    NO INDICATION OF INJURY      0.99         0.87         0.93        6279
    NONINCAPACITATING INJURY     0.52         0.45         0.48        3196
    REPORTED, NOT EVIDENT        0.39         0.50         0.44        1827

    accuracy                     0.66        12000
    macro avg                    0.42         0.44         0.42        12000
    weighted avg                  0.73         0.66         0.69        12000

=== TUNED ExtraTrees (FS) - TEST ===
Test Accuracy: 0.6617
                                precision    recall  f1-score   support

      FATAL                     0.02         0.17         0.04         212
    INCAPACITATING INJURY       0.14         0.23         0.18         3282
    NO INDICATION OF INJURY      0.99         0.86         0.92        31395
    NONINCAPACITATING INJURY     0.52         0.46         0.49        15977
    REPORTED, NOT EVIDENT        0.39         0.51         0.44         9131

    accuracy                     0.66        59997
    macro avg                    0.41         0.44         0.41        59997
    weighted avg                  0.73         0.66         0.69        59997

```

Şule Kartal

FEATURE SELECTION (MI)

--- FEATURE SELECTION (MI)SONUÇLARI ---

Accuracy: 0.6421154391052886

Weighted F1 Score: 0.6620871844101215

	precision	recall	f1-score	support
FATAL	0.02	0.08	0.03	212
INCAPACITATING INJURY	0.12	0.23	0.16	3282
NO INDICATION OF INJURY	0.94	0.87	0.91	31395
NONINCAPACITATING INJURY	0.51	0.42	0.46	15977
REPORTED, NOT EVIDENT	0.34	0.41	0.38	9131
accuracy			0.64	59997
macro avg	0.39	0.40	0.39	59997
weighted avg	0.69	0.64	0.66	59997

DIMENSION REDUCTION (SVD)

DIMENSION REDUCTION (SVD)

Accuracy: 0.6361484740903712

Weighted F1 Score: 0.6381622285252709

Sınıflandırma Raporu:

	precision	recall	f1-score	support
FATAL	0.02	0.03	0.03	212
INCAPACITATING INJURY	0.11	0.13	0.12	3282
NO INDICATION OF INJURY	0.87	0.87	0.87	31395
NONINCAPACITATING INJURY	0.49	0.48	0.48	15977
REPORTED, NOT EVIDENT	0.32	0.32	0.32	9131
accuracy			0.64	59997
macro avg	0.36	0.36	0.36	59997
weighted avg	0.64	0.64	0.64	59997

===== VALIDATION SONUÇLARI =====

Accuracy: 0.6165744382958864

Macro F1: 0.3856311161830031

	precision	recall	f1-score	support
FATAL	0.02	0.72	0.05	53
INCAPACITATING INJURY	0.15	0.25	0.19	820
NO INDICATION OF INJURY	1.00	0.86	0.93	7849
NONINCAPACITATING INJURY	0.55	0.20	0.30	3994
REPORTED, NOT EVIDENT	0.38	0.62	0.47	2283
accuracy			0.62	14999
macro avg	0.42	0.53	0.39	14999
weighted avg	0.74	0.62	0.65	14999

===== TEST SONUÇLARI =====

Accuracy: 0.6108805440272014

Macro F1: 0.3817031977762918

	precision	recall	f1-score	support
FATAL	0.02	0.63	0.04	212
INCAPACITATING INJURY	0.14	0.24	0.18	3282
NO INDICATION OF INJURY	1.00	0.85	0.92	31395
NONINCAPACITATING INJURY	0.55	0.21	0.30	15977
REPORTED, NOT EVIDENT	0.38	0.62	0.47	9131
accuracy			0.61	59997
macro avg	0.42	0.51	0.38	59997
weighted avg	0.73	0.61	0.64	59997

===== CATBOOST TEST =====

Accuracy: 0.6126139640315349

Precision (Macro): 0.41638045697854364

Recall (Macro): 0.49879507960071034

F1 (Macro): 0.38421277587426883

Classification Report:

	precision	recall	f1-score	support
FATAL	0.02	0.57	0.04	212
INCAPACITATING INJURY	0.14	0.25	0.18	3282
NO INDICATION OF INJURY	1.00	0.85	0.92	31395
NONINCAPACITATING INJURY	0.54	0.23	0.32	15977
REPORTED, NOT EVIDENT	0.38	0.60	0.46	9131
accuracy			0.61	59997
macro avg	0.42	0.50	0.38	59997
weighted avg	0.73	0.61	0.65	59997

=====
MLP VALIDATION
=====
Accuracy: 0.7092472831522102
Precision (Macro): 0.4087511623367413
Recall (Macro): 0.39206082786564667
F1 (Macro): 0.3838298223959308

Classification Report (VAL):

	precision	recall	f1-score	support
FATAL	0.00	0.00	0.00	53
INCAPACITATING INJURY	0.18	0.03	0.05	820
NO INDICATION OF INJURY	0.95	0.89	0.92	7849
NONINCAPACITATING INJURY	0.51	0.74	0.60	3994
REPORTED, NOT EVIDENT	0.41	0.30	0.35	2283
accuracy			0.71	14999
macro avg	0.41	0.39	0.38	14999
weighted avg	0.70	0.71	0.70	14999

=====
MLP TEST
=====
Accuracy: 0.7111855592779639
Precision (Macro): 0.4256083772947415
Recall (Macro): 0.3978331389314801
F1 (Macro): 0.3904908243591886

Classification Report (TEST):

	precision	recall	f1-score	support
FATAL	0.06	0.00	0.01	212
INCAPACITATING INJURY	0.19	0.03	0.06	3282
NO INDICATION OF INJURY	0.95	0.88	0.91	31395
NONINCAPACITATING INJURY	0.52	0.76	0.61	15977
REPORTED, NOT EVIDENT	0.42	0.31	0.36	9131
accuracy			0.71	59997
macro avg	0.43	0.40	0.39	59997
weighted avg	0.71	0.71	0.70	59997

Dilara Kurtul

Linear SVC Base Model Test Sonuçları

--- Test Sonuçları ---	precision	recall	f1-score	support
FATAL	0.03	0.49	0.05	212
INCAPACITATING INJURY	0.17	0.02	0.03	3282
NO INDICATION OF INJURY	1.00	0.85	0.92	31395
NONINCAPACITATING INJURY	0.53	0.61	0.57	15977
REPORTED, NOT EVIDENT	0.41	0.47	0.44	9131
accuracy			0.68	59997
macro avg	0.43	0.49	0.40	59997
weighted avg	0.74	0.68	0.70	59997

Linear SVC + FS&VT Test Sonuçları

--- Test Sonuçları (VarianceThreshold + SelectKBest) ---	precision	recall	f1-score	support
FATAL	0.02	0.43	0.04	212
INCAPACITATING INJURY	0.21	0.00	0.01	3282
NO INDICATION OF INJURY	1.00	0.85	0.92	31395
NONINCAPACITATING INJURY	0.53	0.63	0.57	15977
REPORTED, NOT EVIDENT	0.41	0.45	0.43	9131
accuracy			0.68	59997
macro avg	0.43	0.47	0.39	59997
weighted avg	0.74	0.68	0.70	59997

Gradient Boosting Classifier Test Sonuçları

	precision	recall	f1-score	support
FATAL	0.20	0.03	0.05	212
INCAPACITATING INJURY	0.29	0.00	0.00	3282
NO INDICATION OF INJURY	0.96	0.88	0.92	31395
NONINCAPACITATING INJURY	0.51	0.86	0.64	15977
REPORTED, NOT EVIDENT	0.50	0.24	0.33	9131
accuracy			0.73	59997
macro avg	0.49	0.40	0.39	59997
weighted avg	0.73	0.73	0.70	59997

--- Test (GB Updated Params) ---	precision	recall	f1-score	support
FATAL	0.20	0.03	0.05	212
INCAPACITATING INJURY	0.29	0.00	0.00	3282
NO INDICATION OF INJURY	0.96	0.88	0.92	31395
NONINCAPACITATING INJURY	0.51	0.86	0.64	15977
REPORTED, NOT EVIDENT	0.50	0.24	0.33	9131
accuracy			0.73	59997
macro avg	0.49	0.40	0.39	59997
weighted avg	0.73	0.73	0.70	59997

LinearSVC – L1 penalty Test Sonuçları

--- Test (LinearSVC L1) ---	precision	recall	f1-score	support
FATAL	0.02	0.48	0.05	212
INCAPACITATING INJURY	0.17	0.02	0.03	3282
NO INDICATION OF INJURY	1.00	0.85	0.92	31395
NONINCAPACITATING INJURY	0.53	0.61	0.57	15977
REPORTED, NOT EVIDENT	0.41	0.47	0.44	9131
accuracy			0.68	59997
macro avg	0.43	0.49	0.40	59997
weighted avg	0.74	0.68	0.70	59997

YAĞMUR DEVECİ

```
=== RandomForest (Base) ===
Accuracy: 0.7024468297886526
F1 Macro: 0.37697662714530183
Recall Macro: 0.3848178441633414
Precision Macro: 0.3920512819470148

Classification Report:
              precision    recall  f1-score   support

     FATAL               0.00      0.00      0.00         53
  INCAPACITATING INJURY    0.12      0.03      0.05         820
NO INDICATION OF INJURY    0.93      0.89      0.91        7849
NONINCAPACITATING INJURY  0.51      0.73      0.60        3994
  REPORTED, NOT EVIDENT    0.40      0.28      0.33        2283

               accuracy                0.70        14999
               macro avg              0.39      0.38        14999
               weighted avg           0.69      0.70      0.69        14999
```

```
=== RandomForest (Base) ===
Accuracy: 0.7024468297886526
F1 Macro: 0.37697662714530183
Recall Macro: 0.3848178441633414
Precision Macro: 0.3920512819470148

Classification Report:
              precision    recall  f1-score   support

     FATAL               0.00      0.00      0.00         53
  INCAPACITATING INJURY    0.12      0.03      0.05         820
NO INDICATION OF INJURY    0.93      0.89      0.91        7849
NONINCAPACITATING INJURY  0.51      0.73      0.60        3994
  REPORTED, NOT EVIDENT    0.40      0.28      0.33        2283

               accuracy                0.70        14999
               macro avg              0.39      0.38        14999
               weighted avg           0.69      0.70      0.69        14999
```

```
=== RandomForest (Base) ===
Accuracy: 0.7024468297886526
F1 Macro: 0.37697662714530183
Recall Macro: 0.3848178441633414
Precision Macro: 0.3920512819470148

Classification Report:
              precision    recall  f1-score   support

     FATAL               0.00      0.00      0.00         53
  INCAPACITATING INJURY    0.12      0.03      0.05         820
NO INDICATION OF INJURY    0.93      0.89      0.91        7849
NONINCAPACITATING INJURY  0.51      0.73      0.60        3994
  REPORTED, NOT EVIDENT    0.40      0.28      0.33        2283

               accuracy                0.70        14999
               macro avg              0.39      0.38        14999
               weighted avg           0.69      0.70      0.69        14999
```

```
=== RandomForest (Base) ===
Accuracy: 0.7024468297886526
F1 Macro: 0.37697662714530183
Recall Macro: 0.3848178441633414
Precision Macro: 0.3920512819470148

Classification Report:
              precision    recall  f1-score   support

     FATAL               0.00      0.00      0.00         53
  INCAPACITATING INJURY    0.12      0.03      0.05         820
NO INDICATION OF INJURY    0.93      0.89      0.91        7849
NONINCAPACITATING INJURY  0.51      0.73      0.60        3994
  REPORTED, NOT EVIDENT    0.40      0.28      0.33        2283

               accuracy                0.70        14999
               macro avg              0.39      0.38        14999
               weighted avg           0.69      0.70      0.69        14999
```

```
=== RandomForest (Base) ===
Accuracy: 0.7024468297886526
F1 Macro: 0.37697662714530183
Recall Macro: 0.3848178441633414
Precision Macro: 0.3920512819470148

Classification Report:
              precision    recall  f1-score   support

     FATAL               0.00      0.00      0.00         53
  INCAPACITATING INJURY    0.12      0.03      0.05         820
NO INDICATION OF INJURY    0.93      0.89      0.91        7849
NONINCAPACITATING INJURY  0.51      0.73      0.60        3994
  REPORTED, NOT EVIDENT    0.40      0.28      0.33        2283

               accuracy                0.70        14999
               macro avg              0.39      0.38        14999
               weighted avg           0.69      0.70      0.69        14999
```

```
--- XGBoost Sonuçları ---
              precision    recall  f1-score   support

     FATAL               0.25      0.00      0.01         212
  INCAPACITATING INJURY    0.25      0.00      0.00        3282
NO INDICATION OF INJURY    0.97      0.88      0.92       31395
NONINCAPACITATING INJURY  0.51      0.86      0.64       15977
  REPORTED, NOT EVIDENT    0.50      0.24      0.33         9131

               accuracy                0.73       59997
               macro avg              0.50      0.40      0.38       59997
               weighted avg           0.73      0.73      0.70       59997
```

```
--- LightGBM Sonuçları ---
              precision    recall  f1-score   support

     FATAL               0.22      0.02      0.03         212
  INCAPACITATING INJURY    0.25      0.00      0.00        3282
NO INDICATION OF INJURY    0.97      0.88      0.92       31395
NONINCAPACITATING INJURY  0.51      0.86      0.64       15977
  REPORTED, NOT EVIDENT    0.49      0.26      0.34         9131

               accuracy                0.73       59997
               macro avg              0.49      0.40      0.39       59997
               weighted avg           0.73      0.73      0.70       59997
```

```
--- OPTİMİZE EDİLMİŞ MODELLERİN TEST SONUÇLARI ---

-> Optimize Edilmiş XGBoost:
              precision    recall  f1-score   support

     FATAL               0.33      0.00      0.01         212
  INCAPACITATING INJURY    0.29      0.00      0.00        3282
NO INDICATION OF INJURY    0.97      0.88      0.92       31395
NONINCAPACITATING INJURY  0.51      0.86      0.64       15977
  REPORTED, NOT EVIDENT    0.50      0.26      0.34         9131

               accuracy                0.73       59997
               macro avg              0.52      0.40      0.38       59997
               weighted avg           0.74      0.73      0.70       59997

-> Optimize Edilmiş LightGBM:
              precision    recall  f1-score   support

     FATAL               0.22      0.01      0.02         212
  INCAPACITATING INJURY    0.48      0.00      0.01        3282
NO INDICATION OF INJURY    0.97      0.88      0.92       31395
NONINCAPACITATING INJURY  0.51      0.86      0.64       15977
  REPORTED, NOT EVIDENT    0.50      0.26      0.34         9131

               accuracy                0.73       59997
               macro avg              0.54      0.40      0.39       59997
               weighted avg           0.75      0.73      0.71       59997
```


14.REFERANSLAR

Veriseti: <https://data.cityofchicago.org/Public-Safety/Traffic-Crashes-Crashes/85ca-t3if>

[1].Türker, G. F., & Gündüz, F. K. (2023). A Study On Traffic Crash Severity Prediction Using Machine Learning Algorithms. Uluslararası Sürdürülebilir Mühendislik ve Teknoloji Dergisi, 7(2), 152-161.

[2].Jiang, Y., Qu, X., Zhang, W., Guo, W., Xu, J., Yu, W., & Chen, Y. (2025). Analyzing Crash Severity: Human Injury Severity Prediction Method Based on Transformer Model. Vehicles, 7(1), 5.

[3].Chakraborty, M., Gates, T. J., & Sinha, S. (2023). Causal analysis and classification of traffic crash injury severity using machine learning algorithms. Data science for transportation, 5(2), 12.